

# ¿Cuánto de esa mejora es el denominador?

## Un control para el recorte de leyenda en mapeo de cultivos desbalanceado

Autoría anónima

Institución anónima

**Resumen** Los mapas de cultivos por parcela se evalúan de forma rutinaria con F1 promediado por clase sobre un catálogo que quien los produce ya ha podado, y la poda se reporta, cuando se reporta, como una propiedad del dato y no como una decisión. Preguntamos cuánto de la mejora resultante corresponde al mecanismo que podó el catálogo y cuánto al denominador más pequeño que la poda crea. Formalizamos dos mecanismos de operación que cambian cobertura por calidad macro, recortar la leyenda prometida y abstenerse en las parcelas de baja confianza, y los evaluamos bajo un protocolo de bloques espaciales que elige el punto de operación fuera de los datos que lo miden, puntúa ambos mecanismos sobre el mismo conjunto de clases y nunca consulta una etiqueta para decidir qué entrega. Frente a un control que puntúa al predictor intacto sobre esa misma leyenda recortada entregándolo todo, la mayor parte de la mejora aparente desaparece: en un primer banco público el control se lleva casi toda; en un segundo, de otro año y otra región, casi la totalidad; y en el tramo donde la cobertura sigue completa, la totalidad, con todos los mecanismos devolviendo cifras idénticas. A igual cobertura, la abstención supera al recorte de leyenda en los dos bancos, y retirar clases por soporte bajo, que es lo que se reporta hacer en la práctica, es el criterio más débil de los que probamos y no es monótono en el número de clases retiradas. Una cifra macro calculada sobre un catálogo podado es, por tanto, ininterpretable sin este control, que cuesta una línea.

**Keywords:** Mapeo de cultivos · Desbalance de clases · Clasificación selectiva · Protocolo de evaluación · Validación cruzada espacial

## 1. Introducción

Un mapa de cultivos por parcela promete un catálogo. El catálogo es una decisión: alguien eligió qué tipos de cultivo va a nombrar el producto y cuáles no, y esa elección se toma mucho antes de que se calcule ninguna cifra de calidad. En la práctica rara vez se reporta como una elección. Llega en una frase sobre que algunas clases tenían muy poca muestra, y la evaluación que sigue se calcula sobre lo que quedó.

Esto importa porque la métrica que domina la literatura de mapeo de cultivos desbalanceado es el F1 promediado por clase, y promediar por clase divide entre

el número de clases. Retirar una clase que el modelo manejaba mal sube el promedio dos veces: una al borrar del numerador un F1 bajo, y otra al encoger el denominador. El segundo efecto no requiere modelo, ni mecanismo, ni trabajo alguno. Es aritmética. Y sin embargo, una mejora producida enteramente por el segundo efecto es indistinguible, en una tabla de resultados, de una mejora producida por un método.

Tomamos esa ambigüedad como objeto de estudio. Consideramos dos mecanismos con los que se puede cambiar cobertura por calidad macro. El primero recorta la leyenda prometida: el producto nombra  $K$  de las  $C$  clases disponibles y declina responder allí donde su predicción sin restringir cae fuera de ellas. El segundo conserva la leyenda completa y se abstiene en las parcelas donde el predictor está menos seguro, en la tradición de la clasificación selectiva [2,7]. Los dos reducen cuánto mapa se entrega, los dos suben la cifra macro, y la pregunta es de cuánto de esa subida es responsable cada uno.

Nuestra respuesta es un control, y es casi vergonzosamente barato. Puntúese al predictor *intacto* sobre esa misma leyenda recortada, entregándolo todo. Lo que ese control recupere nunca lo compró el mecanismo. En un primer banco público de dieciocho clases agronómicas, el control se lleva el 88,3 % de la mejora aparente al pasar de dieciocho clases a ocho. En un segundo banco, de otro año, otra región y otra familia de modelo, se lleva el 95,1 % en el punto de operación preregistrado. Y en el tramo donde la cobertura sigue completa se lleva *toda*: cada mecanismo que probamos devuelve la misma cifra, hasta el cuarto decimal, mientras el promedio macro sube 0,2447.

Del mismo protocolo salen otros dos resultados. A igual cobertura, abstenerse en las parcelas de baja confianza supera al recorte de leyenda en los dos bancos, que es lo contrario de lo que supone la práctica que nos propusimos formalizar. Y retirar clases por soporte bajo, que es el criterio que se reporta usar, es el más débil de los tres que probamos y no es monótono en el número de clases retiradas: retirar más puede empeorar el mapa entregado.

Las contribuciones son las siguientes. Formalizamos los dos mecanismos y damos un protocolo de bloques espaciales que elige el punto de operación fuera de los datos que lo miden, puntúa ambos mecanismos sobre el mismo conjunto de clases para que sus cifras sean comparables, y nunca consulta una etiqueta verdadera para decidir qué parcelas entrega. Cuantificamos la descomposición de la mejora aparente en denominador y mecanismo sobre dos bancos públicos bajo un protocolo que no cambia entre uno y otro. Ordenamos los tres criterios de retirada con intervalos pareados y corrección por multiplicidad. Y mostramos que un meta-modelo de apilamiento entrenado ejecuta esa misma retirada de forma implícita y no declarada, y que la diferencia entre medirla dentro y fuera de muestra basta para invertir la conclusión sobre si el ensamble aporta algo.

## 2. Trabajo relacionado


Organizamos el trabajo relacionado por lo que cada línea establece y por dónde se detiene, porque el hueco que este artículo aborda está en el espacio entre dos literaturas que rara vez se encuentran.

*Clasificación selectiva.* La opción de abstenerse es antigua y está bien caracterizada. La regla de Chow fija el compromiso óptimo entre error y rechazo para una posterior conocida [2], y el tratamiento moderno la extiende a redes profundas con rechazo aprendido o calibrado [7,8,25], con revisiones recientes que cartografían el espacio de diseño [10,9]. Dos refinamientos importan aquí: la observación de que una sola curva de riesgo y cobertura oculta qué grupos pagan la abstención [11], y la extensión de las curvas de rechazo a precisión y exhaustividad en lugar de solo al error [5,16]. Lo que esta literatura no trata es la abstención *por clase*: su unidad de rechazo es la muestra, así que un mecanismo que declina nombrar una categoría entera cae fuera de su formalismo, y la interacción entre ese mecanismo y una métrica promediada por clase no se analiza.

*Estructura de clases en mapeo de cultivos.* El trabajo sobre mapeo de cultivos sí manipula el catálogo de clases, pero como recurso de modelado y no como punto de operación. Turkoglu y colaboradores organizan los tipos de cultivo en una jerarquía y dejan que el modelo retroceda a un nivel más grueso cuando la decisión fina no es fiable [22], que es el mecanismo existente más cercano al recorte de leyenda; la evaluación, sin embargo, reporta exactitud global sobre una sola partición, así que ni el efecto sobre un promedio por clase ni su variabilidad en el espacio quedan medidos. Los esfuerzos de armonización paneuropea afrontan el mismo problema al nivel de la nomenclatura [20,3], y el trabajo de mapeo de grano fino señala el costo de las clases raras sin aislarlo [12,13,4]. En toda esta literatura el catálogo podado se reporta como una propiedad del dato.

*Bancos de datos y modelos temporales.* Evaluamos sobre dos bancos públicos por parcela. PASTIS aporta series Sentinel-2 con anotación panóptica sobre Francia [6]; BreizhCrops aporta una colección por parcela más grande sobre Bretaña, con partición nativa por región administrativa y un reparto de clases extremo [18]. Las arquitecturas temporales que usamos como predictores son estándar: convoluciones temporales [14], autoatención sobre series crudas [19] y transformadores de visión adaptados a series de imágenes satelitales [21]. Ninguna es contribución de este artículo; aportan las posteriores sobre las que opera el protocolo.

*Protocolo de evaluación.* Que el protocolo sea espacial y no aleatorio no es opcional. La validación cruzada que ignora la autocorrelación espacial infla las estimaciones de capacidad predictiva, a veces de forma severa [17,15]. Por eso elegimos cada punto de operación sobre bloques espaciales disjuntos del bloque donde se evalúa. La literatura de ensambles aporta el ingrediente restante, el meta-modelo de apilamiento cuyo comportamiento implícito examinamos [23,24,1], y es precisamente la exigencia de Wolpert de particiones libres de fuga para entrenar



**Figura 1.** Tres parches del fold retenido del banco primario. Arriba, composición en color natural de Sentinel-2 en la toma más cercana al primero de julio. Abajo, la anotación agronómica por parcela. La unidad del producto es la parcela, y el catálogo que estudia este artículo es la lista de nombres que la fila de abajo tiene permitido usar.

el modelo de segundo nivel la que nuestra comparación entre dentro y fuera de muestra pone a prueba.

### 3. Materiales y método

#### 3.1. Datos


Usamos dos bancos públicos por parcela y no ajustamos el protocolo entre uno y otro.

El **banco primario** es PASTIS-R [6], del que tomamos el fold retenido y agregamos la anotación densa a nivel de parcela, con 16 640 parcelas sobre 496 parches de imagen y dieciocho clases agronómicas. Su desbalance es severo: la clase mayoritaria tiene 6 128 parcelas y la minoritaria 103, una razón de unos 60:1.

El **banco de réplica** es BreizhCrops [18], series Sentinel-2 L2A sobre Bretaña para la campaña de 2017, con nueve clases agronómicas y partición nativa por

**Cuadro 1.** Los dos bancos. Los dos se describen con el mismo vector de 185 características temporales, así que la réplica varía dato, año, región y familia de modelo, pero no representación.

|                         | primario (PASTIS-R)    | réplica (BreizhCrops) |
|-------------------------|------------------------|-----------------------|
| Campaña                 | 2018–2019              | 2017                  |
| Región                  | Francia metropolitana  | Bretaña               |
| Parcelas puntuadas      | 16 640                 | 60 000                |
| Clases                  | 18                     | 9                     |
| Clase mayoritaria       | 6 128                  | 18 113                |
| Clase minoritaria       | 103                    | 2                     |
| Razón de desbalance     | 60:1                   | 9 057:1               |
| Bloques                 | 5 espaciales (H3)      | 2 regiones            |
| Predictor               | miembros preentrenados | gradiente potenciado  |
| Partición del predictor | fold retenido          | una región fuera      |



**Figura 2.** Soporte por clase en escala logarítmica. Las barras por debajo de 300 parcelas van en el color de acento: son las clases que todo criterio de retirada quita primero. La cola del banco de réplica no es solo más delgada, es degenerada —dos y siete parcelas—, y eso es lo que hace posible el pasillo de la sección 4.1.

región administrativa. Usamos las regiones `frh01` y `frh04` con un submuestreo estratificado proporcional de 30 000 parcelas cada una y semilla fija, 60 000 en total. Su desbalance es un orden de magnitud peor que el del banco primario: en el índice completo la clase mayoritaria supera a la menor hasta por 19 207:1, y en nuestro submuestreo tres de las nueve clases tienen dos, siete y 289 parcelas respectivamente. Los dos bancos se describen con el mismo vector de 185 características temporales, derivado de diecisiete índices espectrales, de modo que los dos experimentos difieren en dato y modelo pero no en representación.

### 3.2. Predictores

El protocolo opera sobre posteriores y es indiferente a cómo se produjeron. En el banco primario tomamos los dos más fuertes de diez miembros disponibles,

un transformador de visión para series de imágenes satelitales [21] y un modelo de gradiente potenciado sobre incrustaciones aprendidas. En el banco de réplica entrenamos un clasificador de gradiente potenciado *dejando una región fuera*: la posterior de cada parcela viene de un modelo que nunca vio su región, así que toda posterior que puntuamos es una predicción genuinamente fuera de región. Ese clasificador alcanza F1-macro 0,4979 y exactitud 0,7421 en `frh01`, y 0,4811 y 0,7257 en `frh04`.

### 3.3. Bloques

Todo punto de operación se elige sobre datos disjuntos de los datos que lo miden. En el banco primario los bloques son espaciales: una teselación H3 de resolución cinco, agrupada y separada por un colchón de 1 km, que da cinco bloques. En el banco de réplica el índice publicado no trae coordenadas por parcela, así que la estructura espacial más fina disponible es la región administrativa; usamos las dos regiones como los dos bloques. Es una limitación real y la tratamos como tal: con dos bloques el remuestreo captura la variación *dentro* de las regiones y no *entre* ellas, así que reportamos la diferencia por bloque de cada contraste y no solo un intervalo agregado.

### 3.4. Los dos mecanismos, y un tercer criterio

Sea  $\mathcal{C}$  el conjunto completo de  $C$  clases,  $p(\cdot \mid x)$  la posterior del predictor para la parcela  $x$  y  $\hat{y}(x) = \arg \max_{c \in \mathcal{C}} p(c \mid x)$  su predicción sin restringir.

El *recorte de leyenda* elige un subconjunto  $\mathcal{L} \subseteq \mathcal{C}$  con  $|\mathcal{L}| = K$  sobre los bloques de entrenamiento, y en el bloque de evaluación entrega una parcela cuando  $\hat{y}(x) \in \mathcal{L}$ , emitiendo  $\arg \max_{c \in \mathcal{L}} p(c \mid x)$ . Probamos dos criterios para elegir  $\mathcal{L}$ : por F1 por clase sobre los bloques de entrenamiento, y por soporte de clase sobre esos mismos bloques, el segundo porque es lo que se reporta hacer en la práctica.

El *rechazo por confianza* conserva  $\mathcal{L} = \mathcal{C}$  y entrega las parcelas cuyo  $\max_c p(c \mid x)$  supera un umbral. El umbral es el cuantil de las confianzas del propio bloque que iguala el número de parcelas que el mecanismo comparado entregó en ese mismo bloque, de modo que los dos se comparan a igual cobertura.

Ningún mecanismo lee una etiqueta verdadera para decidir qué entrega. Vale la pena decirlo con todas sus letras porque la implementación natural del recorte de leyenda sí la lee: entregar las parcelas cuya etiqueta *verdadera* cae en  $\mathcal{L}$  es un oráculo, e infla la calidad aparente del mecanismo. Nuestra regla de entrega usa el argmax sin restringir, que es observable en inferencia.

### 3.5. El estimando alineado

Dos mecanismos que prometen catálogos distintos no se pueden comparar por el promedio macro de cada uno, porque los promedios se toman sobre denominadores distintos. Por eso puntuamos todo mecanismo con

$$F1_{\text{alineado}} = \frac{1}{|\mathcal{L} \cap \mathcal{Y}|} \sum_{c \in \mathcal{L} \cap \mathcal{Y}} F1_c, \quad (1)$$

donde  $\mathcal{L}$  es la leyenda bajo prueba e  $\mathcal{Y}$  las clases realmente presentes entre las parcelas entregadas. Los dos mecanismos de un contraste se puntúan sobre la *misma*  $\mathcal{L}$ . Reportamos también el macro nativo de cada mecanismo sobre lo que promete individualmente, pero solo como vista de producto; no es comparable entre mecanismos y nunca lo usamos para un contraste.

### 3.6. El control

El control que da título a este artículo cabe en una línea. Para cada leyenda  $\mathcal{L}$  y cada bloque, puntúese al predictor intacto sobre  $\mathcal{L}$  con la ecuación 1 entregando *todas* las parcelas. No se retira ninguna clase de la emisión ni se rechaza ninguna parcela; solo cambia el denominador. Si ese control iguala o supera a un mecanismo, la calidad la compró la elección del conjunto de clases y no el mecanismo.

### 3.7. Inferencia

Los contrastes usan un remuestreo pareado: se sortea un índice por bloque y se vuelven a puntuar *los dos* mecanismos sobre él, de modo que comparten el ruido de muestreo. Sorteamos 1 000 remuestreos y reportamos el intervalo percentil de la diferencia de medias del F1 alineado por bloque, junto con las diferencias por bloque. En el banco primario remuestreamos además por parche de imagen en vez de por parcela, porque las parcelas de un mismo parche comparten imagen y no son independientes. El criterio principal preregistrado es  $K = \lceil C/2 \rceil$ ; los demás valores de  $K$  forman una familia exploratoria, corregida con el procedimiento descendente de Holm y Bonferroni dentro de cada predictor y cada banco.

## 4. Resultados


### 4.1. El pasillo donde todos los mecanismos son idénticos

En el banco de réplica, recortar el catálogo de nueve clases a seis sube el F1 macro alineado de 0,4895 a 0,7342, una mejora aparente de 0,2447. En todo ese tramo las cuatro series —retirada por F1, retirada por soporte, rechazo por confianza y el control que no aplica mecanismo alguno— devuelven el *mismo* valor, y la cobertura se queda en 1,000.

La razón es aritmética y es lo que hace concluyente la observación. Las tres clases que se retiran primero tienen dos, siete y 289 parcelas de 60 000; el argmax sin restringir prácticamente nunca las predice, así que quitarlas de la leyenda no quita ninguna parcela del mapa entregado. Ningún mecanismo hace nada. La métrica sube casi un cuarto de punto por su cuenta.

**Cuadro 2.** Descomposición de la mejora aparente en el banco de réplica, universo de nueve clases. La columna «denominador» es el control de la sección 3.6: el predictor intacto puntuado sobre la misma leyenda, entregándolo todo.  $K = 5$  es el criterio principal preregistrado.

| $K$      | F1 alineado   | mejora aparente | denominador             | mecanismo              | cobertura    |
|----------|---------------|-----------------|-------------------------|------------------------|--------------|
| 9        | 0,4895        | —               | —                       | —                      | 1,000        |
| 8        | 0,5507        | +0,0612         | +0,0612 (100,0 %)       | +0,0000 (0,0 %)        | 1,000        |
| 7        | 0,6293        | +0,1398         | +0,1398 (100,0 %)       | +0,0000 (0,0 %)        | 1,000        |
| 6        | 0,7342        | +0,2447         | +0,2447 (100,0 %)       | +0,0000 (0,0 %)        | 1,000        |
| <b>5</b> | <b>0,8055</b> | <b>+0,3160</b>  | <b>+0,3004 (95,1 %)</b> | <b>+0,0156 (4,9 %)</b> | <b>0,859</b> |
| 4        | 0,8579        | +0,3684         | +0,3352 (91,0 %)        | +0,0333 (9,0 %)        | 0,806        |
| 3        | 0,9126        | +0,4232         | +0,3826 (90,4 %)        | +0,0406 (9,6 %)        | 0,444        |




**Figura 3.** La misma frontera en el banco primario, para sus dos predictores más fuertes. El control que no aplica mecanismo (cruces) ya recupera la mayor parte de la distancia recorrida por los mecanismos, y la retirada por soporte (cuadrados) vuelve a quedar por debajo de los otros dos en todo el recorrido.

#### 4.2. La descomposición se transporta

El mismo protocolo, sin cambios, da la misma respuesta cualitativa en el banco primario. Recortar de dieciocho clases a ocho sube el F1 macro alineado de 0,561 2 a 0,805 2, una mejora aparente de 0,244 0, de la cual el control recupera 0,215 5, es decir el 88,3 %. En el punto de operación preregistrado,  $K = 9$ , el control recupera el 87,1 %, y el resultado se sostiene en los dos predictores que probamos.

Dos bancos, dos años, dos regiones, dos familias de modelo y un solo protocolo coinciden, por tanto: manda el denominador. Donde difieren es en grado, y en la dirección que importa para quien despliega: el banco de réplica, cuyo desbalance es un orden de magnitud peor, deja al mecanismo aún menos que explicar.



**Figura 4.** Frontera de calidad y cobertura en el banco de réplica, en los dos universos de clases preregistrados. Las cuatro series son indistinguibles hasta  $K = 6$  porque la cobertura es completa y ningún mecanismo actúa; la línea punteada marca el criterio principal. La retirada por soporte (cuadrados) es la única serie que baja conforme se retiran más clases.

#### 4.3. A igual cobertura, gana la abstención


Una vez que la cobertura baja de uno y los mecanismos empiezan a diferir, se pueden ordenar. En el criterio principal del banco de réplica, el rechazo por confianza alcanza 0,8303 frente a 0,8055 del recorte de leyenda a la misma cobertura, una diferencia de  $-0,0248$  con intervalo pareado al 95 % de  $(-0,0272, -0,0225)$  y  $p$  corregido por Holm por debajo de 0,0001. Las dos regiones coinciden en signo y magnitud, con  $-0,0248$  y  $-0,0249$ .

En el banco primario la diferencia tiene el mismo signo pero no se distingue de cero:  $-0,0288$  con intervalo de  $(-0,0414, +0,0080)$  y  $p$  corregido por Holm de 0,336. El resumen honesto sobre los dos bancos es, por tanto, que no encontramos evidencia de que recortar la leyenda supere a la abstención, y que en el banco mayor y más desbalanceado encontramos evidencia significativa de lo contrario.

#### 4.4. La retirada por soporte es el criterio más débil, y no es monótona

Retirar clases por soporte bajo es el criterio que se reporta usar, y es el peor de los tres en los dos bancos. En el banco de réplica alcanza 0,7129 en el criterio principal frente a 0,8055 de la retirada por F1, una brecha de 0,0926 que se ensancha hasta 0,2085 en  $K = 3$ . En el banco primario la brecha correspondiente está entre 0,12 y 0,13.

Hace además algo que ninguno de los otros dos hace: *empeora* conforme se retiran más clases, de 0,7129 en  $K = 5$  a 0,7041 en  $K = 3$ . Inspeccionar las leyendas lo explica. La retirada por soporte quita la colza, que tiene 1718 parcelas y que el modelo separa bien, mientras conserva las dos clases de pradera, que




**Figura 5.** Las mismas mediciones dibujadas contra la cobertura entregada en vez de contra el tamaño de la leyenda, que es como las lee la literatura de clasificación selectiva. El control (cruces) vive en la vertical de cobertura uno por construcción, porque nunca retiene nada; lo que la figura enseña es cuántas de esas cruces quedan *por encima* de las curvas de los mecanismos a cobertura menor.

el modelo confunde entre sí. El criterio optimiza el tamaño de muestra, que no es la misma cantidad que la calidad de lo que se entrega. La figura 6 enseña la sustitución directamente.

#### 4.5. Un meta-modelo entrenado retira clases de forma implícita

El mecanismo que este artículo formaliza ya lo aplican, sin declararlo, los ensamblajes entrenados. En el banco primario, un meta-modelo de apilamiento sobre tres miembros lleva una clase de 355 parcelas a un F1 de exactamente 0,000 0, mientras que el mejor modelo individual alcanza 0,779 0 en esa misma clase. El meta-modelo ha retirado una clase del producto sin que nadie lo decidiera, y sin que aparezca en ninguna tabla de resultados.

El régimen en que se mide ese meta-modelo es decisivo. Puntuado dentro de muestra —reajustado sobre todas las parcelas después de la validación cruzada, que es el comportamiento por omisión de muchas implementaciones de apilamiento— reporta 0,747 0. Puntuado libre de fuga, agrupando sus posteriores espaciales fuera de fold y puntuando una sola vez, reporta 0,678 9. Promediar los macros por bloque en lugar de agrupar reporta 0,536 0. La fuga cuesta 0,068 y la forma de agregar otros 0,143; confundir las dos lleva a reportar 0,536 como la cifra honesta cuando es 0,679, y castiga al modelo por un artefacto de medición encima de su error real. Frente al mejor modelo individual, el meta-modelo libre de fuga pierde por 0,057 2 con un intervalo de  $(-0,0644, -0,0499)$  que excluye el cero.



**Figura 6.** Qué clases conserva cada criterio conforme se recorta la leyenda, en el banco de réplica; una celda llena significa que la clase se promete. La retirada por soporte (derecha) suelta la colza en  $K = 5$  mientras conserva las dos clases de pradera, que el modelo confunde entre sí; la retirada por calidad (izquierda) hace lo contrario. Los dos criterios discrepan justamente en las clases que deciden el resultado.

**Cuadro 3.** F1 por clase en el banco primario, libre de fuga, ordenado por soporte. El árbitro entrenado es el único combinador que lleva una clase a cero, y lo hace con una de 355 parcelas que todos los demás —incluida la media sin entrenar— manejan por encima de 0,77. La retirada es, por tanto, un comportamiento aprendido y no una propiedad de combinar.

| Clase                     | soporte    | mejor indiv.  | media         | voto pond.    | árbitro       |
|---------------------------|------------|---------------|---------------|---------------|---------------|
| Meadow                    | 6 128      | 0,9099        | 0,8980        | 0,9046        | 0,9138        |
| Corn                      | 2 196      | 0,9295        | 0,8683        | 0,9053        | 0,9274        |
| Grapevine                 | 2 067      | 0,9066        | 0,9141        | 0,9154        | 0,9124        |
| Soft winter wheat         | 1 584      | 0,8922        | 0,8466        | 0,8712        | 0,8886        |
| Leguminous fodder         | 660        | 0,5087        | 0,3498        | 0,4707        | 0,5243        |
| Winter rapeseed           | 387        | 0,9358        | 0,9153        | 0,9275        | 0,9377        |
| <b>Winter durum wheat</b> | <b>355</b> | <b>0,7790</b> | <b>0,7752</b> | <b>0,7782</b> | <b>0,0000</b> |
| Spring barley             | 198        | 0,6667        | 0,4691        | 0,5879        | 0,5228        |
| Mixed cereal              | 193        | 0,4949        | 0,3525        | 0,4302        | 0,2709        |
| Potatoes                  | 103        | 0,5595        | 0,5143        | 0,5638        | 0,5823        |

**Cuadro 4.** El mismo meta-modelo de apilamiento bajo tres estimadores. No son tres opciones plausibles: el primero está contaminado y el tercero lo castiga un artefacto de agregación.

| Estimador                         | F1 macro | qué mide                          |
|-----------------------------------|----------|-----------------------------------|
| Reajuste sobre todas las parcelas | 0,7470   | dentro de muestra                 |
| Agrupado fuera de fold            | 0,6789   | libre de fuga, puntuado una vez   |
| Media de macros por bloque        | 0,5360   | libre de fuga, sesgado al agregar |

## 5. Discusión

*Qué compra realmente cada mecanismo.* El recorte de leyenda y el rechazo por confianza cambian los dos cobertura por calidad macro, pero le cobran a clientes distintos. Recortar la leyenda rechaza un tipo de cultivo entero en todas partes: quien lo siembra no recibe nada, en ninguna parcela, en ninguna región. La abstención rechaza parcelas sueltas repartidas entre todos los cultivos, así que ningún productor queda excluido de forma sistemática, que es la propia preocupación de la literatura de clasificación selectiva sobre quién paga la abstención [11]. Nuestras mediciones dicen además que la abstención es la mejor compra a igual cobertura. Los dos argumentos apuntan en la misma dirección, y no conocemos escenario operativo en que sea preferible lo contrario salvo uno: cuando el consumidor aguas abajo exige un catálogo fijo y publicado y no puede actuar sobre un mapa parcial.

*Qué habría que reportar.* Una cifra promediada por clase calculada sobre un catálogo podado es ininterpretable por sí sola, y el arreglo no es caro ni novedoso. Repórtese el número de clases sobre el que se toma el promedio, la cobertura que el producto entrega, y el control de la sección 3.6. Tres números, uno de los cuales cuesta una sola línea de código. Sin ellos, un artículo que sube el F1 macro un cuarto de punto tras retirar tres clases raras está reportando aritmética, y quien lo lee no puede distinguirlo de un artículo que mejoró un modelo.

*Sobre el criterio que se usa en la práctica.* Que la retirada por soporte sea a la vez el criterio más débil y no monótona merece énfasis, porque el soporte es el criterio que se usa. Se elige por una razón defendible —una clase con pocas muestras es una clase cuya estimación es inestable— pero inestabilidad de la estimación y mala separabilidad son propiedades distintas, y el soporte solo rastrea la primera. Una clase con 1 718 parcelas que el modelo separa limpiamente aporta más a un mapa entregado que dos clases abundantes que el modelo no logra distinguir. Elegir por calidad por clase medida, sobre bloques disjuntos de aquellos donde se evaluará, no cuesta nada más y es estrictamente mejor en todas las comparaciones que corrimos.

*Sobre cómo medir meta-modelos.* Las tres cifras del mismo modelo de apilamiento —0,747 0, 0,678 9 y 0,536 0— no son tres estimaciones plausibles entre las que elegir. La primera está contaminada, y la formulación original del apilamiento ya exigía las particiones libres de fuga que ella viola [23]. La tercera está libre de fuga pero castiga al modelo por un artefacto de agregación: promediar macros por bloque en un escenario desbalanceado puntúa cada bloque sobre clases que sus parcelas no contienen. Agrupar las posteriores fuera de fold y puntuar una sola vez, que da 0,678 9, es el estimador que responde a la pregunta que de verdad se está haciendo. La distancia entre la primera y la última es lo bastante ancha como para invertir una conclusión sobre si el ensamble aporta algo, y por eso el régimen tiene que declararse cada vez que se imprime una cifra así.

## 6. Limitaciones y conclusión

*Limitaciones.* Los dos bancos son franceses, así que la réplica varía año, región, reparto de clases y familia de modelo, pero no el sistema agrícola; queda abierto si la descomposición se sostiene en un paisaje de agricultura de pequeña escala. En el banco de réplica los bloques son las dos regiones administrativas, porque el índice publicado no trae coordenadas por parcela, así que nuestro remuestreo captura la variación dentro de las regiones y no entre ellas; por eso reportamos las diferencias por bloque. Ese banco exigió además imputar el 1,62 % de las celdas de características, concentradas en índices de cociente cuyo denominador involucra una banda que la colección codifica como cero para el píxel enmascarado; la imputación usa solo la mediana de la región de entrenamiento, y no puede favorecer a un mecanismo sobre otro porque todos leen la misma posterior. Por último, nuestras posteriores fuera de fold en el banco primario existen para un solo fold, y por eso el meta-modelo de la sección 4.5 se entrena con pocos datos; eso es una limitación de los artefactos de que disponemos, no una afirmación sobre el apilamiento en general.

*Conclusión.* El F1 promediado por clase sobre un catálogo podado mezcla dos cosas que quien lee no puede separar: lo que hizo el método y lo que hizo el denominador más pequeño. Dimos un protocolo que las separa, y la respuesta en dos bancos públicos es que manda el denominador: el 88 % en el primero, el 95 % en el segundo en el punto de operación preregistrado, y el 100 % en el tramo donde la cobertura sigue completa y todos los mecanismos devuelven una cifra idéntica. A igual cobertura no encontramos evidencia de que recortar la leyenda supere a abstenerse, y sí evidencia significativa de lo contrario en el banco más desbalanceado; el criterio que se reporta usar, la retirada por soporte bajo, es el más débil que probamos y empeora conforme se retiran más clases. Nada de esto exige un modelo nuevo. Exige reportar el número de clases, la cobertura y una línea de control junto a cada cifra macro calculada sobre un catálogo que alguien eligió.

### A. Reproducibilidad

Toda cifra impresa en este artículo se re-deriva desde un archivo bajo control de versiones cuyo MD5, tamaño y guion productor constan en un registro de custodia, y una comprobación recalcula esos resúmenes y falla cuando alguno cambia sin quedar registrado. El registro tiene hoy 65 artefactos sellados. Los dos bancos son públicos. Los puntos de operación, los universos de clases y el criterio principal  $K = \lceil C/2 \rceil$  se fijaron en un preregistro escrito antes de correr el experimento de réplica; las dos desviaciones que el dato obligó a hacer —la elección de bloques y el tratamiento de las celdas no finitas— se anotaron como enmiendas fechadas antes de calcular ningún contraste, junto con el error de medición en nuestra propia estimación de costo que una de ellas corrigió.

## Referencias

1. Abdali, E., Zoj, M.J.V., Dehkordi, A.T., Ghaderpour, E.: A parallel-cascaded ensemble of machine learning models for crop type classification in google Earth engine using multi-temporal Sentinel-1/2 and landsat-8/9 remote sensing data. *Remote Sensing* (2023). <https://doi.org/10.3390/rs16010127>
2. Chow, C.: On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory* (1970). <https://doi.org/10.1109/tit.1970.1054406>
3. Claverie, M., Chan, A., See, L., Ramos, H., Koebler, R., Yordanov, M., et al.: EuroCrops v2.0: multi-annual harmonized parcel level crop type data linked to european union-wide survey, statistical, and Earth observation products. *Earth System Science Data* (2026). <https://doi.org/10.5194/essd-18-4075-2026>
4. Donmez, E., Heckelet, T., Storm, H.: Satellite remote sensing-based crop cover classification over europe: accuracy of different methodological approaches. *International Journal of Remote Sensing* (2025). <https://doi.org/10.1080/01431161.2025.2565837>
5. Fischer, L., Wollstadt, P.: Precision and recall reject curves for classification (2023)
6. Garnot, V.S.F., Landrieu, L.: Panoptic segmentation of satellite image time series with convolutional temporal attention networks (2021)
7. Geifman, Y., El-Yaniv, R.: Selective classification for deep neural networks (2017)
8. Geifman, Y., El-Yaniv, R.: Selectivenet: A deep neural network with an integrated reject option (2019)
9. Hasan, M., Abdar, M., Khosravi, A., Aickelin, U., Lio', P., Hossain, I., et al.: Survey on leveraging uncertainty estimation towards trustworthy deep neural networks: The case of reject option and post-training processing (2023)
10. Hendrickx, K., Perini, L., der Plas, D.V., Meert, W., Davis, J.: Machine learning with a reject option: a survey. *Machine Learning* (2024). <https://doi.org/10.1007/s10994-024-06534-x>
11. Jones, E., Sagawa, S., Koh, P.W., Kumar, A., Liang, P.: Selective classification can magnify disparities across groups (2020)
12. Lei, L., Wang, X., Zhong, Y., Zhang, L.: Finecrop: Mapping fine-grained crops using class-aware feature decoupling and parcel-aware class rebalancing with Sentinel-2 time series. *ISPRS Journal of Photogrammetry and Remote Sensing* (2025). <https://doi.org/10.1016/j.isprsjprs.2025.07.041>
13. Li, D., Wang, S., He, Q., Yang, Y.: Cost-effective land cover classification for remote sensing images (2021)
14. Pelletier, C., Webb, G., Petitjean, F.: Temporal convolutional neural network for the classification of satellite image time series. *Remote Sensing* (2019). <https://doi.org/10.3390/rs11050523>
15. Ploton, P., Mortier, F., Réjou-Méchain, M., Barbier, N., Picard, N., Rossi, V., et al.: Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nature Communications* (2020). <https://doi.org/10.1038/s41467-020-18321-y>
16. Pugnana, A., Ruggieri, S.: AUC-based selective classification (2022)
17. Roberts, D.R., Bahn, V., Ciuti, S., Boyce, M.S., Elith, J., Guiller-Arroita, G., et al.: Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography* (2017). <https://doi.org/10.1111/ecog.02881>
18. Rufwurm, M., Pelletier, C., Zollner, M., Lefèvre, S., Körner, M.: Breizhcrops: A time series dataset for crop type mapping. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences* (2020). <https://doi.org/10.5194/isprs-archives-xliii-b2-2020-1545-2020>

19. Rußwurm, M., Körner, M.: Self-attention for raw optical satellite time series classification. *ISPRS Journal of Photogrammetry and Remote Sensing* (2020). <https://doi.org/10.1016/j.isprsjprs.2020.06.006>
20. Schneider, M., Broszeit, A., Körner, M.: EuroCrops: A pan-european dataset for time series crop type classification. *elib* (German Aerospace Center) (2021). <https://doi.org/10.14459/2021mp1615987>
21. Tarasiou, M., Chavez, E., Zafeiriou, S.: Vits for SITS: Vision transformers for satellite image time series (2023)
22. Turkoglu, M.O., D'Aronco, S., Perich, G., Liebisch, F., Streit, C., Schindler, K., et al.: Crop mapping from image time series: deep learning with multi-scale label hierarchies (2021)
23. Wolpert, D.H.: Stacked generalization. *Neural Networks* (1992). [https://doi.org/10.1016/s0893-6080\(05\)80023-1](https://doi.org/10.1016/s0893-6080(05)80023-1)
24. Zhang, Y., Liu, J., Shen, W.: A review of ensemble learning algorithms used in remote sensing applications. *Applied Sciences* (2022). <https://doi.org/10.3390/app12178654>
25. Ziyin, L., Wang, Z., Liang, P.P., Salakhutdinov, R., Morency, L.P., Ueda, M.: Deep gamblers: Learning to abstain with portfolio theory (2019)