

Prometer menos para equivocarse menos: cuatro mecanismos de renuncia como acciones alternativas en el mapeo de cultivos

Autores anónimos

Afiliación omitida para la revisión por doble ciego

Resumen Un mapa de cultivos incierto puede reducir el catálogo que promete, abstenerse, devolver etiquetas plausibles o retroceder a una categoría agronómica más gruesa. Los trabajos previos tratan estas cuatro acciones como líneas separadas, con óptimos y evaluaciones diferentes. Dentro de nuestra búsqueda acotada no encontramos una comparación que las formule como un solo problema de decisión y pregunte qué se concluye sin escoger el precio de cada resultado. Primero fijamos el estimando y la población; cada punto de operación se obtiene solo de entrenamiento y validación; y conservamos el espacio completo de pérdidas de seis coordenadas. Los datos identifican vectores de frecuencia, dominancia uniforme y fronteras lineales de cambio; la preferencia de una parte interesada requiere un punto de pérdida externo. En una reejecución congelada de diez semillas de las etapas posteriores al entrenamiento de PASTIS-R, ningún par de acciones dentro del mismo predictor quedó certificado como dominante. El atlas original identificó un ganador único en 3913 de 6600 evaluaciones modelo-pérdida; las reejecuciones abarcaron 3915–3973, y los mismos cuatro tipos de acción ganaron en alguna región. Estos conteos no son volumen del simplex, y la búsqueda acotada no halló un banco confirmatorio admisible. Retrospectivamente, un catálogo desplegado de doce clases entregó respuesta en 15265 de 16640 parcelas, y ninguna de treinta configuraciones alternativas congeladas dominó su perfil. La evidencia determina regiones de cambio, no una única mejor manera de prometer menos.

Keywords: Mapeo de cultivos · Clasificación selectiva · Predicción de conjuntos · Teoría de decisión · Series temporales de imágenes satelitales

1. Introducción

Un mapa de cultivos a nivel de parcela es una promesa. Nombra un cultivo para cada campo de la escena, y alguien actúa después con base en ese nombre: un inspector programa una visita, un agrónomo planea un insumo o una agencia liquida un subsidio. Cuando el clasificador duda, responder de todos modos transfiere la incertidumbre a esa persona sin avisarle.

Hay más de una manera de decir menos. El mapa puede *reducir el catálogo* que está dispuesto a prometer y dejar de ofrecer las clases que no separa; puede

abstenerse para una parcela y derivarla a una persona; puede devolver un *conjunto de etiquetas candidatas* para que el lector elija; o puede *retroceder* a una categoría agronómica más gruesa que sí puede defender. Cada opción compra precisión con una moneda distinta y desplaza el coste a otro lugar.

Prometer menos para equivocarse menos no es una idea nueva. El compromiso error–rechazo se debe a Chow [3]; Ha lo generalizó después a la selección de un *subconjunto* de clases, junto con su criterio de optimalidad [10]. Trabajos recientes dan algoritmos eficientes para el subconjunto de máxima utilidad esperada [14] y sistematizan las formulaciones disponibles [4]. En mapeo de cultivos, el tamaño del catálogo ya se midió como variable de diseño [7]; y el trabajo más cercano rechaza píxeles por incertidumbre en el mismo banco y con tres arquitecturas también representadas en nuestro banco original, haciendo explícito el compromiso entre precisión y recobrado [16].

Lo que no encontramos fue una comparación de estos mecanismos *entre sí*. Cada línea optimiza su propio dispositivo y reporta su propia curva. Dentro del alcance de búsqueda descrito en la Sección 2, no encontramos un trabajo que reúna reducción de catálogo, abstención, respuestas por conjuntos y retroceso taxonómico en un mismo problema de decisión, conserve el espacio completo de pérdidas y pregunte qué conclusiones son invariantes a todo precio admisible.

Contribución. Formulamos la comparación y las condiciones bajo las cuales puede creerse. En concreto: (i) tratamos los cuatro mecanismos como *acciones* alternativas de un mismo problema y representamos cada una mediante su vector completo de frecuencias de resultado; (ii) fijamos el estimando, la población y la unidad de análisis *antes* de calcular, y exigimos que cada punto de operación proceda únicamente de entrenamiento y validación; (iii) derivamos dominancia uniforme y fronteras de cambio sobre todo el espacio normalizado de pérdidas, en vez de escoger un punto favorable; y (iv) reportamos la distribución de resultados entre clases, pues un mecanismo que mejora un promedio descartando en silencio clases raras ya no mejora el mismo mapa.

Lo que este artículo no afirma. No inferimos de las salidas del modelo las preferencias de una parte interesada ni elegimos un punto de pérdida en su nombre. La evidencia puede identificar dominancia uniforme y la frontera en la que una acción pasa a ser preferible; no puede ubicar en ese espacio a un inspector, asesor o productor concreto. Todo punto externo posterior es una sensibilidad declarada, no una entrada oculta del análisis primario. La búsqueda registrada cerró sin un banco confirmatorio admisible y su log de consultas específico no fue versionado; por ello, la ausencia se limita al conjunto documentado de candidatos y no a toda la literatura. Los dos bancos parcelarios disponibles siguen siendo exploratorios. Los diagnósticos conformes y jerárquicos que siguen no cambian ese papel ni constituyen una comparación terminada de las cuatro acciones.

2. Trabajo relacionado

Organizamos esta sección por *limitación* y no por aplicación: para cada línea de trabajo decimos qué establece y dónde se detiene, porque ese punto define lo que todavía falta.

El marco de renuncia ya existe. El compromiso error–rechazo y su regla óptima se deben a Chow [3]; esa formulación es el caso degenerado en el que la única alternativa a responder es el silencio. Ha la generalizó al rechazo selectivo por clase y demostró que elegir un subconjunto de clases es el compromiso óptimo entre error y número medio de clases devueltas [10]; el tratamiento es de teoría de decisión y supone conocidas las posteriores. La regla selectiva de Ha es una familia parametrizada implementada. No perteneció a la familia de seis brazos ya ejecutada; una extensión exploratoria prospectiva congela un miembro derivado de validación como séptimo brazo, sin convertirlo en comparación confirmatoria. Mortier et al. dan algoritmos para el subconjunto Bayes-óptimo de máxima utilidad esperada, con una utilidad que depende del tamaño del conjunto [14]; Chzhen et al. unifican las formulaciones y sus compromisos [4], a muestra infinita y bajo un principio de sustitución. El marco no es nuestra contribución. Estos tratamientos comparten que el precio de una respuesta es función de *su tamaño*; no comparan las cuatro acciones con el mismo espacio completo de pérdidas específicas por resultado.

La abstención aprendida está desarrollada y queda fuera por decisión. La clasificación selectiva profunda ofrece garantías de riesgo [5], una arquitectura con cabeza de rechazo integrada [6], una pérdida de tipo apuesta [12] y un criterio de selección basado en AUC [15]. Todas se abstienen *por instancia*; ninguna emite un conjunto ni retrocede a una clase gruesa. No las reimplementamos ni comparamos contra ellas: preguntamos cómo se compara la abstención con las otras tres acciones bajo un espacio común de pérdidas, no si existe una regla de abstención mejor.

La renuncia llegó a observación de la Tierra, pero no desde la agricultura. El trabajo más cercano rechaza píxeles mediante un umbral de incertidumbre en PASTIS, usa tres arquitecturas del banco candidato original y explicita el compromiso: no responder reduce el recobrado y puede elevar la precisión cuando el píxel rechazado habría sido mal clasificado [16]. Es el compromiso riesgo–cobertura, ejecutado y reconocido. No lo sitúa en el marco de clasificación selectiva, no compara acciones alternativas ni caracteriza las fronteras del espacio de pérdidas donde cambia la acción preferida. En otros dominios de observación terrestre, SHRUG-FM reporta abstención con umbrales interpretables [9] para cicatrices de incendio, inundaciones y deslizamientos, no para agricultura. Métodos de rechazo se aplicaron a mapeo de vegetación [8] con datos hiperespectrales aerotransportados, no con series satelitales por parcela. El reconocimiento abierto de cultivos rechaza lo *desconocido* mediante exposición a atípicos [2], una pregunta distinta de repartir el grado de promesa entre clases conocidas.

El tamaño del catálogo ya es una variable de diseño medida. Ghassemi et al. tratan y miden el número de clases como variable de diseño: partiendo de 52 clases LUCAS, un esquema de 26 equilibra precisión y detalle [7]. Es el precedente directo para leer la reducción del catálogo como punto de operación e impide afirmar que somos los primeros. Allí el contexto es cobertura del suelo con Random Forest; aquí es uno de cuatro mecanismos, representado en un vocabulario común de resultados sobre todo el espacio admisible.

El retroceso taxonómico ya tiene precedente en mapeo de cultivos. Las jerarquías de etiquetas multiescala mejoran el mapeo desde series temporales satelitales [19]. Ese trabajo predice en tres granularidades y permite que la confianza determine la granularidad de salida; es un precedente directo del retroceso taxonómico guiado por confianza, no solo del entrenamiento jerárquico. La fusión jerárquica también combina señales satelitales, rotacionales y contextuales [1], pero para fusionar información y no para entregar granularidad variable. No reclamamos como nuevo el retroceso. También se formalizó la predicción jerárquica de conjuntos usando nodos internos como conjuntos válidos habituales [13]. La comparación abierta es si esta acción es uniformemente preferible a otra y, de no serlo, dónde está su frontera.

Los efectos distributivos están documentados fuera de nuestro dominio. La clasificación selectiva puede *amplificar* disparidades entre grupos: abstenerse más puede empeorar sus resultados [11]. La evidencia corresponde a grupos demográficos en visión y lenguaje, no a clases agronómicas o parcelas. La usamos como razón para reportar distribución entre clases, no como evidencia sobre cultivos, y señalamos que contradice la intuición de que negarse a responder sea neutral.

Novedad, con su universo declarado. No encontramos un trabajo que compare reducción de catálogo, abstención por parcela, predicción de conjuntos y retroceso taxonómico *como acciones alternativas del mismo problema*, reporte su orden de dominancia uniforme sobre el espacio completo de pérdidas específicas y contabilice la distribución de los resultados entre clases. La afirmación está acotada por nuestra búsqueda: arXiv, OpenAlex y Semantic Scholar, 61 consultas automáticas y 6 manuales, entre 2019–2026 más los clásicos recuperados por nombre, solo en inglés. El procedimiento indexa mal las actas de teledetección sin DOI y usa el vocabulario de clasificación selectiva; observamos este sesgo porque el trabajo más cercano [16] no emplea esos términos y apareció por otra vía.

3. Formulación del problema y estimando

3.1. Cuatro maneras de prometer menos

Sea $\mathcal{Y}$ el catálogo de clases, x_i las observaciones de la parcela i y $y_i \in \mathcal{Y}$ su etiqueta de referencia. Un clasificador convencional se compromete con un mapeo $x_i \mapsto \hat{y}_i \in \mathcal{Y}$: debe nombrar exactamente una clase para cada parcela, sin importar la forma de su posterior. Todos los mecanismos comparados relajan ese

compromiso de la misma manera formal. Sustituyen la predicción puntual por un subconjunto,

$$C_m(x_i) \subseteq \mathcal{Y}, \quad C_m(x_i) = \emptyset \text{ permitido}, \quad (1)$$

y solo difieren en los subconjuntos que pueden emitir y en qué fija la elección.

Reducción del catálogo. Se fija un subcatálogo $\mathcal{S} \subset \mathcal{Y}$ antes de observar parcelas. Si el máximo de la posterior sin restricciones cae dentro de $\mathcal{S}$, se entrega el máximo restringido; si cae fuera, no se entrega nada. La regla lee la posterior, no la etiqueta de referencia: condicionar la entrega a la verdad haría imposible el mecanismo durante la inferencia, aunque una implementación anterior hizo exactamente eso. La decisión se toma una vez por clase.

Abstención por parcela. Se emite un singleton o el conjunto vacío según si una medida de confianza supera un punto de operación. La decisión se toma por parcela.

Predicción de conjuntos. Se emite un subconjunto no vacío cuyo tamaño cambia con la dificultad de la parcela, calibrado para sostener una garantía poblacional declarada. Toda parcela recibe respuesta; cambia cuánto se compromete esa respuesta.

Retroceso taxonómico. Se emite el conjunto de hojas bajo un nodo de una jerarquía de clases. Formalmente es otro subconjunto; lo distingue que los subconjuntos admisibles son categorías que un agrónomo puede nombrar, de modo que la respuesta baja a una categoría más gruesa pero comunicable, no a una lista arbitraria.

Dos elementos degenerados delimitan el mismo espacio: la predicción singleton sobre el catálogo completo, que no renuncia a nada, y la no entrega universal, con $C \equiv \emptyset$. Ninguno es un mecanismo, pues ninguno elige a qué renunciar. Tampoco ocupan el mismo papel: la línea base sí se evalúa como referencia para poner precio a toda renuncia; la no entrega universal solo fija la frontera del precio del silencio y nunca se ejecuta. Escribir todo en un mismo espacio de acciones permite formular la pregunta: mientras diseño de leyenda, umbrales, calibración conforme y predicción jerárquica sean técnicas separadas, no existe un objeto común sobre el que preguntar cuál se debe preferir.

3.2. El estimando

Fijemos un banco d con su región, campaña, partición y predictor, y un mecanismo m que opera en τ_m . Cada parcela retenida cae exactamente en una celda de una cuenta cerrada: entrega precisa correcta, entrega precisa incorrecta, no entrega, conjunto que contiene o excluye la verdad, o respuesta gruesa que contiene o excluye la verdad. La entrega precisa correcta es la referencia de

pérdida cero R_0 ; las demás celdas son $L_1, \dots, L_6$. La cantidad empírica es su vector de frecuencias,

$$q_{d,m,j} = \frac{1}{N_d} \sum_{i=1}^{N_d} \mathbf{1}\{O_i(m) = L_j\}, \quad j = 1, \dots, 6, \quad (2)$$

donde N_d cuenta *todas* las parcelas elegibles del bloque. Para todo vector finito no negativo, una escala positiva común no cambia el orden; normalizamos entonces

$$\ell \in \Delta^5 = \left\{ \ell \in \mathbb{R}_+^6 : \sum_{j=1}^6 \ell_j = 1 \right\}, \quad R_{d,m}(\ell) = \mathbf{q}_{d,m}^\top \ell. \quad (3)$$

Los datos determinan $\mathbf{q}$, no ℓ . Reportamos por ello la geometría lineal completa en vez de insertar un punto. El brazo m domina uniformemente a n exactamente cuando $q_{m,j} \leq q_{n,j}$ en toda celda con coste y al menos una desigualdad es estricta. Si no, su frontera de cambio es el hiperplano $(\mathbf{q}_m - \mathbf{q}_n)^\top \ell = 0$. Un precio escalar solo existe dentro de una sección declarada que fija las demás coordenadas. Una figura bidimensional es una vista de sensibilidad, no el espacio completo de cinco dimensiones.

La cardinalidad no es la pérdida. El tamaño esperado cobra igual dos conjuntos de igual tamaño aunque uno excluya la verdad y asigna tamaño cero a la no entrega. Lo conservamos como descriptor, nunca como objetivo común. Tampoco inferimos un punto de pérdida de las salidas: eso convertiría una preferencia de modelado en resultado de datos. Un punto externo posterior puede superponerse como sensibilidad no confirmatoria, declarando su procedencia.

La población incluye las parcelas sin entrega. N_d recorre toda parcela elegible, incluidas las que el mecanismo no responde y aquellas cuya clase dejó de pertenecer al catálogo reducido. Restringir el denominador a entregas pondría precio cero a la renuncia y evaluaría cada mecanismo en una población que él mismo elige, permitiéndole mejorar al responder menos.

El punto de operación se fija antes de tocar el bloque retenido. τ_m se deriva íntegramente de entrenamiento y validación. El bloque retenido estima el resultado realizado y nada más. Se prohíbe reigualar pérdida, cobertura o tasa de entrega en ese bloque, incluso como ajuste posterior para hacer comparables los mecanismos: es la fuga que dos auditorías encontraron en una versión anterior, primero en el umbral y después en su tasa objetivo.

3.3. Alcance, dependencia y afirmaciones excluidas

La inferencia es *condicional a cada banco*, con su región, campaña, partición y predictor. La unidad observacional es la parcela. Las parcelas no son independientes: llegan en parches que comparten adquisición, geografía y anotación; por

ello el clúster es el parche. El bootstrap remuestrea parches completos dentro de bloques espaciales y nunca parcelas individuales. El atlas primario de PASTIS-R trata su fold externo retenido como un estrato y remuestrea sus parches. Una sensibilidad separada reparte esos mismos parches en cada k declarado y reejecuta toda la familia; no elimina parcelas ni convierte subdivisiones en territorios independientes. Con menos de tres clústeres pareados únicos, el perfil se reporta de forma descriptiva sin inferencia, pues el intervalo describiría el esquema de remuestreo y no los datos.

No se agrupa ninguna cantidad entre bancos. Cada uno se reporta por separado; el segundo ofrece un contraste descriptivo de región externa y no otra muestra del primero. El número de bloques es un parámetro de sensibilidad para agrupar la misma evidencia, no un número de réplicas ni una palanca de potencia estadística.

Lo que el diseño sacrifica se declara aquí porque limita cada afirmación posterior: **no afirmamos transporte**. Nada observado en una región o campaña se supone válido en otra. El estimando condicional es lo que permiten las particiones disponibles; uno marginal requeriría una muestra de regiones que no tenemos. Una versión anterior mezcló ambos hasta que la auditoría los separó.

El contexto de despliegue deseado es México, pero la búsqueda acotada no identificó un banco público mexicano con etiquetas de cultivo por parcela. Los bancos disponibles no validan esa geografía. Es una limitación de la evidencia, no prueba de que esos datos no existan, y ningún resultado siguiente se generaliza desde las regiones evaluadas hacia México.

4. Cuatro mecanismos como acciones alternativas

El análisis principal materializa cuatro mecanismos posteriores al entrenamiento como seis brazos: línea base, dos ordenamientos del catálogo, abstención, predicción de conjuntos y retroceso taxonómico. No cubren todo el retículo. Las cascadas cambian información y cómputo; los umbrales por clase añaden parámetros escasos ajustados en validación; los rechazadores aprendidos cambian el entrenamiento. Las políticas aprendidas, adaptativas por clase y multietapa siguen sin explorarse; las afirmaciones se limitan a estos cuatro puntos y a los dos ordenamientos. La no entrega universal es una frontera. Por combinación modelo–estrato, la extensión prospectiva de Ha fija su coste en la segunda posterior más alta mínima de validación que alcanza el objetivo singleton, sin etiquetas retenidas ni reigualación; sin banco confirmatorio, es diagnóstico y no prueba de admisión.

4.1. Un tipo de salida común

Cada brazo devuelve el vector booleano de pertenencia de $C_m(x_i)$ sobre el catálogo fijo. La representación no contiene etiqueta de referencia, pérdida ni filtro de solo entregas. Una fila con un verdadero es una entrega precisa; con varios, una entrega ambigua o gruesa; toda falsa es no entrega. Mantener el conjunto

vacío dentro del tipo de salida evita que una parcela abstendida desaparezca antes de contarla.

La línea base emite el singleton del máximo posterior. Ambos brazos de reducción aplican el mismo operador a un subcatálogo predeclarado distinto. Si el máximo sin restricciones pertenece al subcatálogo, se emite; si no, la salida es vacía. El operador no mira la referencia. Los brazos solo difieren en la regla de entrenamiento que ordena las clases a retirar, no en el tratamiento de una parcela de prueba.

La abstención emite el máximo cuando su confianza supera un umbral fijo y el vacío en otro caso. La predicción de conjuntos ordena etiquetas por posterior y emite el prefijo no vacío más corto que alcanza una masa acumulada calibrada. El constructor aplica esa masa, pero no la estima: la calibración pertenece a entrenamiento y validación, y cualquier garantía depende de ella.

El brazo de conjuntos usa conjuntos adaptativos split-conformal deterministas y no aleatorizados. Para cada parcela de calibración, la puntuación es la masa posterior acumulada hasta la etiqueta verdadera bajo un orden estable. La masa se selecciona mediante el rango exacto de estadístico de orden finito $\lceil (n_{\text{cal}} + 1)(1 - \alpha) \rceil$, no pasando una fracción de rango a una API de cuantiles que interpola. Si el rango excede la muestra, se emite el catálogo completo y no el mayor puntaje observado. La convención determinista evita otra aleatorización y semilla; su posible conservadurismo se reporta mediante contención marginal y tamaño observado. La cobertura retenida se mide sobre todas las parcelas y puede caer bajo el nivel nominal en una realización finita; se reporta y nunca se usa para recalibrar la masa.

El retroceso taxonómico usa un corte HCAT de cuarta edición predeclarado sobre las hojas. Una parcela confiable conserva el singleton; una incierta recibe todas las hojas representadas bajo el nodo que contiene el máximo posterior. El mapeo comprometido resuelve cada hoja y nodo contra la taxonomía EuroCrops antes de predecir, y rechaza asignaciones ausentes, repetidas, no ancestrales o fuera del catálogo. Tres nodos contienen una sola hoja del estudio; retroceder allí deja visible el singleton en vez de saltar después a un nodo más ancho. Una jerarquía mal formada no puede convertir en silencio una parcela en no entrega; una jerarquía más profunda sería otra regla de operación.

Todos los puntos de operación —catálogo retenido, umbral, masa calibrada y partición gruesa— son entradas de los operadores. Ninguno se ajusta dentro de ellos ni puede reiguarse en el bloque retenido. Esta separación vuelve inspeccionable la invariancia a etiquetas: cambiarlas no cambia el conjunto entregado.

La invariancia es propiedad de los operadores; la disyunción de bloques es responsabilidad de quien los llama. Un punto ajustado conserva identidades estables de las filas usadas y se niega a aplicarse sobre cualquiera de ellas. La identidad no se infiere de los bytes de las posteriores: parcelas distintas pueden compartirlas y recalcular la misma parcela puede cambiar sus bytes. Entregar de nuevo el bloque evaluado como calibración falla explícitamente, en lugar de dejar pasar la fuga observada en una versión anterior.

La interfaz impone el orden temporal. El ajuste acepta arreglos de entrenamiento y validación sin argumento de prueba; la aplicación acepta posteriores retenidas sin etiquetas; solo el evaluador recibe etiquetas, cuando ya existen las seis matrices. Una única ruta compone las etapas sin proporcionar valores pre-determinados para tamaño de catálogo, entrega, desajuste, retroceso, jerarquía o pérdida. Así, una elección ausente del preregistro no se vuelve un valor por defecto.

El catálogo de hojas viene fijado por la salida del modelo en entrenamiento. Por separado, un universo neutral se selecciona una sola vez desde etiquetas de entrenamiento mediante el piso de soporte. Validación y prueba no añaden ni quitan clases. Cada brazo conserva toda parcela en su denominador, incluidas no entregas y clases fuera del resumen neutral. Una clase seleccionada pero ausente sigue visible con soporte cero y estadístico indefinido; no se elimina ni se convierte en cero válido. Cada frecuencia y diagnóstico usa denominadores fijados antes de observar la entrega.

4.2. La rejilla completa acción–resultado

La interfaz sigue la rejilla completa del contrato. Una etiqueta precisa es correcta —referencia de pérdida cero— o incorrecta. El conjunto vacío es no respuesta. Un conjunto con varias etiquetas contiene o excluye la verdad. Una clase gruesa también contiene o excluye la verdad. Son siete celdas. Las dos fallas de respuestas no singleton son indispensables: sin ellas, conjuntos y respuestas gruesas solo pagarían cuando aciertan y adquirirían otra falla gratuita.

La celda se decide por la entrega visible, no por el nombre del algoritmo. Un singleton del brazo de conjuntos se puntúa como etiqueta precisa. Una entrega múltiple se distingue como conjunto libre o clase gruesa nombrada, pues sus consecuencias pueden diferir. Una fila vacía es no respuesta en todo brazo. Cada parcela ocupa exactamente una celda.

El evaluador primario cuenta las siete celdas y devuelve el vector completo sin aceptar un punto de pérdida. Una interfaz separada de sensibilidad acepta seis pérdidas finitas no negativas, mantiene en cero la etiqueta precisa correcta y rechaza mapeos incompletos. Al quitar la escala común, los puntos forman un simplex de cinco dimensiones. Puntos sintéticos prueban que cambiar el precio relativo de error y silencio puede invertir la acción de menor riesgo; no se vuelven preferencias empíricas.

Cada frecuencia usa el mismo denominador de la Ec. (2), incluidas las no entregas. El riesgo en cualquier sensibilidad declarada es el producto punto de la Ec. (3). El tamaño esperado sigue siendo descriptivo; la utilidad heredada basada en tamaño se vincula de forma diagnóstica con el macro-recobrado, pero no ordena los brazos.

5. Protocolo de evaluación

El protocolo estima primero el vector completo de frecuencias de cada brazo y después deriva la dominancia y la geometría de cambio para toda pérdida

normalizada. No necesita un punto de pérdida, y ningún contraste empírico se ejecutó para escribir esta sección.

5.1. Orden de particiones y formación de pares

Los bancos empíricos son la modalidad óptica de PASTIS-R [18] y Breizh-Crops [17]. Nombrar PASTIS-R identifica el banco distribuido; ningún canal radar entra a los predictores evaluados.

Entrenamiento fija el universo neutral y el catálogo por soporte; validación fija los demás componentes del punto de operación; evaluación empieza solo cuando ambos son inmutables. Las identidades estables imponen particiones disjuntas e impiden aplicar un punto ajustado a cualquier identidad de entrenamiento o validación, incluso una fila copiada; la igualdad de posteriores es irrelevante.

El tamaño común del catálogo es el prefijo más corto de clases ordenadas por soporte de entrenamiento cuya masa acumulada alcanza 0,9, desempataando por id de clase; las reglas por F y soporte usan ese mismo tamaño. Validación fija una entrega objetivo de 0,9 para abstención, un desajuste de 0,1 para el conjunto adaptativo y una tasa precisa de hoja de 0,9 para retroceso. Una clase entra al universo neutral con al menos 20 parcelas de entrenamiento. Son puntos de intervención nominales elegidos por los autores, no puntos de igual pérdida, y no se reigualan en la partición retenida.

El evaluador asigna cada parcela retenida y cada brazo a uno de los siete resultados cerrados. El pareo usa identidad, bloque y `patch_id`; reordenar filas es válido, pero omitir, duplicar o sustituir no. El universo derivado de entrenamiento viaja con el perfil y nunca se reconstruye desde evaluación o desde una réplica bootstrap.

Los artefactos portan su régimen evidencial en vez de heredarlo del nombre. Un inventario cerrado cubre la raíz de resultados; cada registro empírico y fila de custodia repite un régimen. Solo los diagnósticos de diseño PDF o SVG sellados directamente en el directorio de figuras son excepciones no empíricas. Un resultado confirmatorio debe identificar un banco retenido congelado y descender de su preregistro; el inventario actual es solo exploratorio y no puede reclasificar los bancos ya vistos.

El registro del tercer banco contiene 14 candidatos de dos rondas y ninguno admisible. Sin log de consultas versionado, esto sustenta un resultado negativo acotado a esas entradas, no una búsqueda exhaustiva. Cardinalidad, geografía, partición espacial y descarga son criterios de los autores. La rama vacía deja ambos bancos como exploratorios; reabrirlos exige una enmienda previa.

5.2. Dos vistas declaradas de incertidumbre

Para cada par de brazos y celda, el contraste es el indicador del brazo izquierdo menos el de su comparador. La vista primaria remuestrea grupos completos de `patch_id` dentro de bloques, lleva juntas todas las parcelas y brazos y combina bloques con sus pesos parcelarios originales. No hay bootstrap de parcelas.

Por separado, las diferencias se promedian dentro de bloques espaciales y esas medias reciben peso igual. Un intervalo de Student pareado sobre una coordenada o sección declarada expone la variación entre bloques sin tratar folds superpuestos como regiones independientes. Su centro puede diferir del contraste poblacional cuando cambian los tamaños; forzar igualdad cambiaría el estimando.

Ambas vistas conservan el denominador completo. Por debajo de tres unidades pareadas únicas, se devuelven deltas y una razón, pero no intervalo, valor p ni elegibilidad Holm. Una comparación declarada idéntica por construcción se conserva como autocontrol y se excluye de multiplicidad.

5.3. Selección de partición espacial y sensibilidad

El barrido escalar original agrupaba centroides de parcelas y podía excluir parcelas del colchón y partir un parche. La corrección divide parches completos, representados por la media proyectada de sus centroides, y conserva todo parche y parcela en cada k . La selección usa solo la razón entre separación mínima de representantes y colchón de construcción; el umbral congelado no prueba independencia espacial ni diagnostica autocorrelación residual.

Cero o varios candidatos elegibles dejan k sin seleccionar sin suprimir la curva. Toda la familia simultánea se reejecuta en cada partición, cuya huella cierra pertenencias. La sensibilidad no puede sobrescribir el atlas, crear territorios ni sumar potencia.

5.4. La potencia usa la misma unidad que su prueba

El efecto mínimo detectable del análisis pareado por bloques se obtiene de la distribución de Student no central, no sumando dos cuantiles centrales. Para n bloques pareados independientes, grados $\nu = n - 1$, desviación supuesta σ y nivel por prueba α^* , sea

$$c = t_{1-\alpha^*/2, \nu}, \quad \lambda = \frac{\delta\sqrt{n}}{\sigma}. \quad (4)$$

Se resuelve el menor $|\delta|$ tal que

$$\Pr\{T_\nu(\lambda) < -c\} + \Pr\{T_\nu(\lambda) > c\} \geq 1 - \beta. \quad (5)$$

La escala de planeación tiene fuente independiente del resultado y no se estima del contraste juzgado; los conteos hipotéticos usan efecto predeclarado, nunca el delta observado. Identificadores repetidos no aumentan n , menos de tres unidades no dan MDE publicable y varianza observada cero no es escala de planeación cero. Contrastes sin ajustar usan $\alpha^* = \alpha$; una familia Holm de tamaño m usa prospectivamente $\alpha^* = \alpha/m$.

Este cálculo pertenece solo al estimando de bloques con peso igual. No describe el análisis primario por parches, cuya potencia depende de perfiles prospectivos y estructura de clústeres y se evalúa por simulación. Llamar al MDE de bloques potencia del estimando primario recrearía el desajuste de unidad. El código corre con entradas sintéticas, pero aquí no se reporta MDE empírico.

5.5. Dominancia, fronteras y multiplicidad

Cada estrato contiene todos los pares no ordenados y las seis coordenadas con coste. Para un par ordenado, el escalar primario es

$$D_{m,n} = \max_{j=1,\dots,6} (q_{m,j} - q_{n,j}). \quad (6)$$

La dominancia componente a componente observada es descriptiva. Una afirmación inferencial exige que toda cota unilateral simultánea sea a lo sumo cero y al menos una estrictamente menor. Las cotas vienen de un estadístico máximo sobre la familia completa. No se retiran pares ni coordenadas después de verlos. Si falta una comparación o tiene pocos clústeres, se retiene la afirmación simultánea afectada y quedan disponibles los vectores descriptivos.

El procedimiento primario congelado usa alfa familiar 0,05, intervalos del 95 %, 9,999 remuestreos pareados de parches dentro de bloque, probabilidades bootstrap add-one y semilla 20260909. En cada estrato confirmatorio, el valor crítico es el máximo absoluto de la desviación estudentizada centrada sobre los 15 pares y 6 costes: 90 coordenadas o 180 desigualdades direccionales. Un error estándar cero retiene la afirmación, salvo donde ninguna acción pueda producir ese resultado: la diferencia es cero exacto en todo clúster, por lo que la cota exacta es cero y no lleva probabilidad bootstrap. Esta cota estructural es esencial; sin ella el par no puede conservar seis coordenadas acotadas. Registramos la aclaración después de ejecutar y rederivamos las dos salidas afectadas antes del envío. La estudentización se recalcula dentro de cada réplica con su propio error de parche centrado por bloque; se prohíbe reutilizar un denominador. Una relación entre predictores usa intersección–unión y debe sostener la misma dirección en todo estrato predeclarado; no se elige el predictor favorable.

La región ganadora ajustada de m es la intersección del simplex con los semiespacios $(\mathbf{q}_m - \mathbf{q}_n)^T \boldsymbol{\ell} \leq 0$ para cada comparador n . La frontera de un par es la igualdad. Estos objetos usan todas las coordenadas y no requieren una medida de probabilidad sobre el simplex. Toda sección bidimensional debe declarar qué fija; no puede rotularse como mapa completo ni convertirse en umbral escalar universal.

El análisis separado de distribución por clase usa la desviación absoluta media sin ponderar entre clases de la retención de promesa. En recorte, la retención vale uno si la hoja verdadera pertenece a la leyenda ajustada; en abstención es la tasa condicional de entrega no vacía. Los dos contrastes planeados son catálogo por F menos abstención y catálogo por soporte menos abstención, con dirección positiva y una familia Holm de dos. Si falta una clase del universo fijado en entrenamiento, se retiene toda H2 en vez de cambiar el denominador. La igualdad observada no prueba equivalencia.

Las pérdidas puntuales se limitan a sensibilidades no confirmatorias con fuente externa o sección geométrica declarada. No seleccionan el punto de operación, no definen la familia primaria ni sustentan una preferencia de parte interesada. Razones y conjuntos de Fieller anteriores quedan fuera del análisis primario.

La potencia objetivo es 0,8. Su alternativa prospectiva sellada mueve un punto porcentual desde cada una de las seis celdas adversas hacia la referencia

y rota la posición aventajada por los seis brazos. La admisión usa 999 bancos simulados sobre el esqueleto planeado, la misma semilla y bootstrap, y correlaciones intraclúster 0, 0,05, 0,1 y 0,2. La menor cota unilateral de Wilson al 95 % sobre posiciones y correlaciones debe alcanzar el objetivo. La alternativa es una elección autoral, no efecto observado ni margen práctico. Se congeló antes de la ejecución. La búsqueda cerrada no admitió banco confirmatorio, por lo que no existe estructura candidata donde correr la simulación. Sustituirla por PASTIS-R o BreizhCrops contradiría su papel exploratorio.

6. Resultados

Reportamos contabilidad exploratoria de resultados, no una preferencia universal. Para los 5 predictores congelados de PASTIS-R, el atlas primario no certificó dominancia: 71 de 75 pares de acciones fueron ciertamente incomparables y 4 quedaron indeterminados, no empatados. La ausencia de dominancia se mantuvo en las diez semillas. El hallazgo histórico de que ninguna partición espacial fue seleccionada falló en todas las semillas y se retira; sin perfiles de selección por semilla no reportamos reemplazo.

No existe un punto de pérdida preregistrado que marcar: se prohíbe seleccionarlo. Las 20 secciones bidimensionales contienen 66 puntos cada una. Entre predictores son 6600 evaluaciones modelo-pérdida. La corrida histórica tuvo 3913 ganadores ciertos y 2687 evaluaciones indeterminadas; en diez semillas, los rangos fueron 3915–3973 y 2627–2685. Los conteos históricos fueron línea base 2029, conjuntos adaptativos 947, abstención 660 y retroceso 277; los rangos por semilla fueron 2029–2067; 946–949; 661–680; y 277–279. Ambas reglas de catálogo quedaron en 0. Estos conteos de rejilla demuestran cambios, no probabilidades, rangos, fracciones del simplex ni frecuencias bajo una pérdida no declarada.

En el retículo de 1320 puntos, PASTIS-R produjo 1233 victorias del predictor, 83 de la acción —todas de conjuntos adaptativos— y 4 igualdades. Los conteos históricos descriptivos de BreizhCrops fueron 952, 364 y 4 para una región, y 928, 388 y 4 para la otra. Los rangos por semilla fueron 949–982, 334–367 y 4; después 884–948, 368–432 y 4. Estas cotas componente a componente no son realizaciones conjuntas. Tampoco son volúmenes del simplex ni evidencia sobre coste de entrenamiento o modelos futuros.

La Fig. 1 muestra la primera sección de la enumeración exhaustiva, con $L_4 = L_5 = L_6 = 0,1$ y sin agrupar predictores. Se eligió para mostrarla después de materializar, no fue preregistrada. Las 20 secciones siguen disponibles en el artefacto estructurado.

Retrospectivamente, un sistema desplegado anonimizado redujo dieciocho clases a doce usando el catálogo más grande por F1 superior cuyo F1 medio por clase seguía al menos en 0.90 sobre el mismo fold —no un umbral por clase—. Entregó el argmax restringido solo cuando el argmax crudo estaba retenido: 15265 de 16640 parcelas (0.9174), con 13617 correctas, 1648 incorrectas y 1375 no entregadas; cuatro celdas fueron cero estructural. Las cuentas anteriores 14688




Figura 1. Regiones de ganador cierto en una sección declarada del atlas exploratorio PASTIS-R. Los símbolos identifican la acción ganadora; las cruces son evaluaciones donde la banda simultánea no establece una. Cada panel es un predictor congelado. Las acciones de restricción del catálogo permanecen en la leyenda aunque ninguna gane en esta sección, cerrando la cuenta de seis acciones. La sección mostrada es la primera de la enumeración congelada y fue elegida para presentación después de obtener resultados.

(0.8827) indican etiquetas de referencia dentro del catálogo, no cobertura de entrega.

Ninguna de treinta configuraciones predictor–acción congeladas dominó ese perfil; él dominó cinco y cruzó veinticinco. Son comparaciones de sistemas completos, no un efecto aislado del mecanismo ni una pérdida implícita identificada.

BreizhCrops no aporta un atlas inferencial pareado. Cada estrato modelo–región contiene 1 clúster bajo la unidad congelada, por debajo del mínimo de 3; no son estimables intervalos simultáneos, dominancia ni fronteras de fase. Sus perfiles siguen descriptivos y no se agrupa con PASTIS-R para fabricar replicación.

La masa conforme y el umbral preciso HCAT4 se ajustaron en validación. Ambas entregas quedaron fijadas antes de abrir las etiquetas de evaluación; la disponibilidad de referencias solo restringió entregas ya fijadas de PASTIS-R. Sus objetivos de validación son restricciones distintas, no una pérdida igual.

Cada fila conforme cumplió su objetivo marginal, pero devolviendo respuestas múltiples. HCAT4 recuperó entregas adicionales que contenían la verdad en cada fila, pero también emitió respuestas gruesas incorrectas en cada una. Su tasa precisa realizada varió entre estratos pese a un objetivo único de validación. Una clase gruesa nombrada no es rescate gratuito ni el mismo objeto que un conjunto arbitrario que contiene la verdad.

Una auditoría posresultado declarada ajustó una temperatura solo en validación por modelo-estrato. Sustituyó el disparador original de ECE de validación cuando la primera corrida no sellada mostró que ampliar un subconjunto seleccionado requería etiquetas retenidas. En evaluación, la pérdida logarítmica bajó en cada fila; ECE de etiqueta superior y Brier empeoraron cada uno en 3; con el objetivo de entrega 0.9, entrega y precisión selectiva se movieron en ambas direcciones. Es auditoría exploratoria, no afirmación de mejora por recalibración.

La calibración conforme marginal no implicó cobertura condicional por clase: una clase U-Net de PASTIS-R contuvo la verdad en 28 de 206 conjuntos. El soporte extremo histórico en BreizhCrops fue 6 parcelas; los extremos por semillas abarcaron 1–6 y no sostienen generalización por clase.

Las filas usan las poblaciones completas definidas por cada banco: 16640 parcelas PASTIS-R con etiqueta válida y 30000 parcelas BreizhCrops por región externa. Las otras 11892 identidades posteriores de PASTIS-R se excluyeron solo después de fijar la entrega, por lo que la disponibilidad de fichero no redefinió la población.

La Fig. 2 cambia la unidad de parcelas a soporte ráster, conservando el denominador retenido. En cada predictor, los conjuntos adaptativos asignaron la menor fracción a entregas que garantizan excluir la verdad, pero movieron la mayor parte a respuestas ambiguas que la contienen. Todo intervalo de área por cultivo bajo ese brazo tuvo dirección no identificada. HCAT4 produjo signos identificados e intervalos que cruzan cero; singleton y no entrega dieron errores puntuales porque no dejan asignación interna sin resolver. Nada ordena los brazos sin poner precio a ambigüedad, error y silencio.

Área significa soporte del ráster de referencia a diez metros dentro de cada fragmento PASTIS-R, no área catastral o declarada. BreizhCrops no contiene geometría ni área, por lo que su vista de superficie no es estimable y no se substituyó por proxy.

Para cada predictor, la amplitud de entrega no vacía entre clases verdaderas superó la amplitud entre deciles de área definidos en entrenamiento para ambas reglas de catálogo y abstención: soporte de clase y tamaño de parcela no son intercambiables. BreizhCrops aporta solo cobertura por clase.

La familia H2 congelada no admitió intervalos por bloque. Solo 2 de 5 bloques PASTIS-R contenían las 18 clases declaradas en entrenamiento, y cada estrato de BreizhCrops aportó 1 bloque, por debajo del mínimo de 3. La regla retiene toda la familia en vez de cambiar el universo, inventar subregiones o agrupar ajustes de regiones opuestas; H2 no tiene intervalo, valor p ni decisión Holm.




Figura 2. Contabilidad exploratoria del área mapeada en el fold retenido de PASTIS-R. Cada barra divide el área completa para un predictor y regla; no se agrupan predictores. Catálogo, abstención, conjunto adaptativo y jerarquía conservan categorías distintas. Las fracciones describen contabilidad de entrega, no estimaciones puntuales de área ni utilidades.

Estos diagnósticos explican las coordenadas donde cambia el atlas; no suministran un punto de pérdida. Las figuras retiradas de primera pasada no se restan porque difieren sus catálogos, predictores y puntos de operación.

7. Discusión

Los diagnósticos muestran por qué una sola tasa de éxito no responde a la pregunta de decisión. Los conjuntos conformes logran contención marginal al devolver varias etiquetas; HCAT4 a veces recupera la verdad mediante un padre comunicable y a veces devuelve el padre equivocado. Declarar que cualquiera es uniformemente mejor pondría de forma implícita precio cero a la amplitud o al error grueso, por lo que las coordenadas de resultado deben permanecer separadas.

La afirmación de cobertura está condicionada a cada banco evaluado y a la intercambiabilidad entre sus parcelas de calibración y evaluación. Ambos bancos ya habían sido inspeccionados antes de esta ejecución, de modo que todos los resultados son exploratorios aunque las particiones de evaluación se mantengan fuera de la calibración. No se deriva ninguna afirmación de transporte, y

la búsqueda cerrada no halló otro banco confirmatorio admisible. La variación entre predictores es sensibilidad, no una vía para seleccionar un modelo favorable. PASTIS-R sostiene por ello un atlas de decisión exploratorio; BreizhCrops sostiene perfiles descriptivos, pero no inferencia pareada, porque su estructura de reporte congelada tiene solo 1 clúster por estrato modelo-región.

La ausencia de dominancia certificada no es un resultado nulo: los perfiles que se cruzan y las victorias de cuatro acciones rechazan un orden independiente del precio y localizan sus cambios. Que la restricción del catálogo no gane ningún punto muestreado no prueba que sus regiones tengan volumen cero, pues la rejilla no define una medida sobre el simplex. La conclusión espacial depende de la semilla: históricamente cambiaron 2 filas y 1 par; por semilla los rangos fueron 0-2 y 0-1, y solo certificaron pares antes indeterminados. Retiramos la afirmación de que no se seleccionó partición y, al no existir perfiles de selección por semilla, no publicamos un reemplazo. Esto es sensibilidad al agrupamiento, no replicación ni fundamento para escoger k .

Ninguna alternativa congelada domina uniformemente al perfil desplegado, por lo que descartarlo requiere un vector de pérdida. Esto no es un contrafactual dentro del predictor: Full-M v2 carece de procedencia de los folds de entrenamiento, el XGBoost histórico no se reprodujo y no sobrevive una posterior de calibración independiente. Se audita lo servido, sin identificar un efecto del catálogo ni un perfil retenido.

El área cartografiada vuelve concreta la ambigüedad sin asignarle precio. Los conjuntos adaptativos evitan área garantizadamente equivocada al devolver conjuntos que contienen la verdad, pero dejan los totales por cultivo parcialmente identificados; HCAT4 estrecha la asignación, aunque un padre incorrecto sigue siendo un error entregado. Un brazo más seguro bajo validez de entrega puede ser, por tanto, el menos informativo para el área de cultivo: es una consecuencia, no una afirmación de preferencia.

La falta del intervalo H2 es un resultado del diseño, no evidencia de igualdad en la no entrega. PASTIS-R incumple el requisito congelado de clases comunes antes de ambos contrastes; BreizhCrops tiene muy pocos bloques independientes. Ninguno de los dos fallos puede repararse cambiando el denominador después de observar la cobertura de clases. La robustez al ruido de etiquetas tampoco está medida: H2 se retuvo antes de todo contraste y no se declaró un modelo de transición de clases específico de banco que permitiera generar una corrupción defendible.

La calibración no es una propiedad intercambiable: el escalado por temperatura redujo la pérdida logarítmica retenida en todas las filas, pero ECE y Brier empeoraron cada uno en 3 estratos de modelo, y los efectos sobre el rechazo fueron mixtos. Los conjuntos adaptativos también expusieron heterogeneidad entre clases. La enmienda declarada audita a cada miembro y no sostiene una mejora genérica.

Los checkpoints heredados de PASTIS-R no registran semillas de entrenamiento en sus fuentes de identidad. La sensibilidad a semillas solo puede reejecutar etapas estocásticas posteriores al entrenamiento para esos miembros; no

establece robustez frente a la aleatoriedad de entrenamiento. No rellenamos esa afirmación reentrenando después de observar el atlas. Se conservan los predichos estables; los conteos que cambiaron se reportan como rangos. El muestreo y los ajustes clásicos de BreizhCrops siguen siendo reejecutables y separados, sin agregarlos.

Disponibilidad de datos y código

El archivo anónimo contiene el proyecto L^AT_EX, la bibliografía, el apéndice generado y las figuras, pero no datos satelitales crudos. Los artefactos exploratorios, contratos y código de regeneración permanecen privados durante la revisión y acompañarán un archivo citable antes de la publicación. Los datos fuente conservan las condiciones de sus proveedores; quienes repliquen el trabajo reejecutarán el atlas y las figuras desde los conteos de resultados depositados, no desde las imágenes.

A. Contratos de análisis congelados

Traducido de diez contratos sellados y comprobados byte a byte; un insumo ausente o divergente detiene la compilación normativa. Aquí no aparece ninguna pérdida observada, ordenación ni contraste.

Estimando y unidades inferenciales. La inferencia condicional al banco, sin agregación, cubre cada parcela elegible retenida, incluida la no entrega; unidad: parcela; clúster: `patch_id`. El universo de clases y el punto de operación se fijan desde entrenamiento y entrenamiento-validación, respectivamente. Con menos de 3 clústeres pareados o 3 bloques espaciales pareados, la vista correspondiente no tiene intervalo, valor p ni decisión Holm. No se afirma transporte.

Espacio completo de pérdidas. R_0 es la referencia de pérdida cero; las 6 celdas de coste son L_1 ; L_2 ; L_3 ; L_4 ; L_5 ; L_6 , normalizadas sobre un símplex de 5 dimensiones. Las frecuencias de los brazos definen dominancia por componente, regiones ganadoras como semiespacios y fronteras en hiperplanos condicionales. No se afirma un punto elicitado ni una preferencia de la parte afectada.

Inferencia congelada. Alfa familiar 0,05; 9999 remuestreos pareados por clúster de parches, semilla 20260909. El máximo cubre 15 pares de brazos por 6 costes (180 desigualdades dirigidas). La potencia objetivo es 0,8 bajo 999 simulaciones prospectivas y una cota Wilson unilateral. Los objetivos de operación son 0,9, 0,9, 0,1 y 0,9; H_2 es una sola familia Holm de dos contrastes. Todas son decisiones de autoría.

Panel de predictores. El predictor es un factor de sensibilidad, no un ganador: 5 miembros de 4 familias (mínimo 3): `unet`; `deeplabv3plus`; `segformer`; `tsvit-pheno`; `tsvit-pheno-fullm`. Toda selección de un solo modelo debe anidarse fuera de la evaluación; los estados e identidades de familia permanecen sellados.

Brazo de predicción por conjuntos. Los conjuntos adaptativos conformes con división determinista usan solo las etiquetas de validación. Se puntúa la probabilidad acumulada hasta la etiqueta verdadera; la acción es el prefijo ordenado no vacío más corto que alcanza la masa calibrada, con desempate por índice de clase. Un rango de muestra finita inalcanzable devuelve el catálogo completo para cada parcela retenida.

Brazo jerárquico. HCAT4 sella cada correspondencia hoja-padre y ajusta la confianza de entrega solo con entrenamiento y validación (pastis-r: 18 hojas, 7 acciones gruesas, 3 correspondencias aproximadas; breizhcrops-2017: 9 hojas, 4 acciones gruesas, 0 correspondencias aproximadas).

Sensibilidad correctiva del perfil. Los grupos completos `patch_id` se particionan en 5; 8; 10; 12; 15; 20; 25, conservando cada parche y parcela. Una partición solo se selecciona cuando la separación representativa alcanza 10,0 veces el colchón de 1,0 km; la selección no condiciona la curva ni reemplaza el atlas primario.

Barrido de desbalance de clases. La rejilla independiente de resultados tiene 20 objetivos: tamaños 3; 4; 5; 6, exponentes de soporte 0,0; 0,25; 0,5; 0,75; 1,0, profundidad 1 y soporte mínimo 100. Sus 6 clases comunes producen 6 salidas cerradas; el barrido es descriptivo y no agregado.

Búsqueda de banco confirmatorio. El registro contiene 14 candidatos adjudicados hasta 2026-09-08, ninguno admitido. Al no existir un registro de consultas, el alcance se limita a ellos y no es globalmente exhaustivo. La elegibilidad es una elección del equipo; ambos bancos siguen siendo exploratorios y reabrir la búsqueda exige una enmienda previa.

Identidades de modelo. Las tuplas congeladas son `tsvit-pheno`: $T = 10$, $d = 128$, entrenamiento/validación 1; 2; 3 / 4; `tsvit-pheno-fullm`: $T = 37$, $d = 192$, entrenamiento/validación 1; 2; 3 / 4; `tsvit-pheno-fullm-v2`: $T = 32$, $d = 192$, entrenamiento/validación no registrado / no registrado. Los MD5 de los checkpoints siguen sellados; los folds ausentes permanecen como “no registrados”.

Referencias

1. Barriere, V., Claverie, M., Schneider, M., Lemoine, G., d’Andrimont, R.: Boosting crop classification by hierarchically fusing satellite, rotational, and contextual data. *Remote Sensing of Environment* **305**, 114110 (2024). <https://doi.org/10.1016/j.rse.2024.114110>
2. Carvalho, T., Martinez, J.A.C., Oliveira, H., dos Santos, J.A., Feitosa, R.Q.: Outlier exposure for open set crop recognition from multitemporal image sequences. *IEEE Geoscience and Remote Sensing Letters* **20**, 1–5 (2023). <https://doi.org/10.1109/LGRS.2023.3244532>
3. Chow, C.: On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory* (1970). <https://doi.org/10.1109/tit.1970.1054406>
4. Chzhen, E., Denis, C., Hebiri, M., Lorieul, T.: Set-valued classification — overview via a unified framework (2021)

5. Geifman, Y., El-Yaniv, R.: Selective classification for deep neural networks. In: Advances in Neural Information Processing Systems 30 (NIPS 2017). pp. 4878–4887. Curran Associates (2017), <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>
6. Geifman, Y., El-Yaniv, R.: SelectiveNet: A deep neural network with an integrated reject option. In: Proceedings of the 36th International Conference on Machine Learning (ICML). Proceedings of Machine Learning Research, vol. 97, pp. 2151–2159. PMLR (2019), <https://proceedings.mlr.press/v97/geifman19a.html>
7. Ghassemi, B., Izquierdo-Verdiguier, E., d’Andrimont, R., Vuolo, F.: How accurately and in what detail can land use and land cover be mapped using copernicus Sentinel and LUCAS 2022 data? Remote Sensing **17**(8), 1379 (2025). <https://doi.org/10.3390/rs17081379>
8. Gimenez, R., Laloue, A., Fabre, S.: Rejection methods for vegetation mapping using hyperspectral airborne data. International Journal of Remote Sensing **44**(16), 4937–4962 (2023). <https://doi.org/10.1080/01431161.2023.2240520>
9. Gonzalez-Calabuig, M., Cohrs, K.H., Nedungadi, V., Osika, Z., Cartuyvels, R., Knoblauch, S., Massant, J., Nath, S., Ebel, P., Sitokoustantinou, V.: SHRUG-FM: Reliability-aware foundation models for Earth observation. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. pp. 7919–7928 (2026)
10. Ha, T.M.: The optimum class-selective rejection rule. IEEE Transactions on Pattern Analysis and Machine Intelligence **19**(6), 608–615 (1997). <https://doi.org/10.1109/34.601248>
11. Jones, E., Sagawa, S., Koh, P.W., Kumar, A., Liang, P.: Selective classification can magnify disparities across groups. In: 9th International Conference on Learning Representations (ICLR) (2021), https://openreview.net/forum?id=NOM_4BkQ05i
12. Liu Ziyin, Wang, Z., Liang, P.P., Salakhutdinov, R., Morency, L.P., Ueda, M.: Deep gamblers: Learning to abstain with portfolio theory. In: Advances in Neural Information Processing Systems 32 (NeurIPS 2019). pp. 10622–10632. Curran Associates (2019), <https://proceedings.neurips.cc/paper/2019/hash/0c4b1eeb45c90b52bfb9d07943d855ab-Abstract.html>
13. Mortier, T., Hüllermeier, E., Dembczyński, K., Waegeman, W.: Set-valued prediction in hierarchical classification with constrained representation complexity. In: Proceedings of the Thirty-Eighth Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research, vol. 180, pp. 1392–1401. PMLR (2022), <https://proceedings.mlr.press/v180/mortier22a.html>
14. Mortier, T., Wydmuch, M., Dembczyński, K., Hüllermeier, E., Waegeman, W.: Efficient set-valued prediction in multi-class classification. Data Mining and Knowledge Discovery **35**, 1435–1469 (2021). <https://doi.org/10.1007/s10618-021-00751-x>
15. Pugnana, A., Ruggieri, S.: AUC-based selective classification. In: Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS). Proceedings of Machine Learning Research, vol. 206, pp. 2494–2514. PMLR (2023), <https://proceedings.mlr.press/v206/pugnana23a.html>
16. Rey, M., Mnih, A., Neumann, M., Overlan, M., Purves, D.: Uncertainty evaluation of segmentation models for Earth observation (2025)
17. Rußwurm, M., Pelletier, C., Zollner, M., Lefèvre, S., Körner, M.: BreizhCrops: A time series dataset for crop type mapping. The International Archives of the

- Photogrammetry, Remote Sensing and Spatial Information Sciences **XLIII-B2-2020**, 1545–1551 (2020). <https://doi.org/10.5194/isprs-archives-XLIII-B2-2020-1545-2020>
18. Sainte Fare Garnot, V., Landrieu, L., Chehata, N.: Multi-modal temporal attention models for crop mapping from satellite time series. *ISPRS Journal of Photogrammetry and Remote Sensing* **187**, 294–305 (2022). <https://doi.org/10.1016/j.isprsjprs.2022.03.012>
 19. Turkoglu, M.O., D'Aronco, S., Perich, G., Liebisch, F., Streit, C., Schindler, K., Wegner, J.D.: Crop mapping from image time series: Deep learning with multi-scale label hierarchies. *Remote Sensing of Environment* **264**, 112603 (2021). <https://doi.org/10.1016/j.rse.2021.112603>