

¿Cuándo debe decir menos un mapa de cultivos?

Comparación de políticas de salida fijas bajo pérdidas no especificadas

Autores anónimos

Afiliación omitida para la revisión por doble ciego

Resumen Un clasificador de cultivos no siempre debe emitir una etiqueta: puede reducir su catálogo, abstenerse, devolver un conjunto o retroceder a una categoría agronómica más gruesa. Comparamos políticas fijas posteriores al entrenamiento de esas cuatro familias mediante una sola cuenta de siete resultados. Seis celdas cargan pérdida; la representación es exacta para pérdidas constantes dentro de esta base predeclarada, no para toda utilidad downstream posible. Los puntos de operación se fijan con entrenamiento y validación, y el bloque retenido estima el vector completo de frecuencias de cada política. Esos vectores identifican dominancia uniforme y fronteras lineales sin elegir la pérdida de un usuario. En cinco predictores congelados sobre la cohorte PASTIS-R con referencia válida, ningún par de políticas dentro de un predictor fue certificado como dominante, mientras cuatro tipos de política fueron preferidos en alguna sección de sensibilidad declarada. BreizhCrops aporta perfiles descriptivos, no inferencia pareada bajo la unidad de agrupamiento congelada. El estudio es exploratorio y condicional a los bancos: no afirma transporte geográfico ni una respuesta universalmente óptima a la incertidumbre. Su contribución es mostrar de forma reproducible cuándo la evidencia decide la política y cuándo la decide el coste.

Keywords: Mapeo de cultivos · Clasificación selectiva · Predicción de conjuntos · Teoría de decisión · Series temporales de imágenes satelitales

1. Introducción

Un mapa de cultivos por parcela es una promesa: un inspector, asesor o una agencia puede actuar sobre cada etiqueta. Cuando el clasificador duda, responder de todos modos transfiere esa incertidumbre sin mostrarla. Sin embargo, un mapa puede prometer menos de varias maneras: reducir su catálogo, abstenerse para una parcela, devolver un conjunto de etiquetas o retroceder a una categoría agronómica más gruesa. Cada acción intercambia un tipo de error por una respuesta incompleta distinta.

Las ideas componentes están establecidas. Chow introdujo el compromiso error-rechazo [5]; Ha lo generalizó al rechazo selectivo por clase [12]; y trabajos posteriores caracterizan decisiones óptimas por conjuntos [17,6]. En mapeo de cultivos, el tamaño del catálogo ya es una variable de diseño medida [9], y el




Figura 1. Tres parches reales de PASTIS-R en color natural Sentinel-2 y sus etiquetas de referencia por parcela. Una regla congelada de densidad y variedad de clases eligió los paneles antes de esta revisión; dan contexto visual y no son ejemplos del modelo.

rechazo por incertidumbre se evaluó en el mismo banco [19]. Lo que sigue sin resolverse es cómo comparar estos dispositivos *entre sí*: cada uno suele fijar su propio objetivo y reportar su propia curva.

Dentro de la búsqueda acotada de la Sección 2, no encontramos una comparación que sitúe instancias fijas de reducción de catálogo, abstención, predicción por conjuntos y retroceso taxonómico en un mismo problema y pregunte qué se sigue sin elegir la pérdida del usuario. Respondemos esa pregunta más estrecha con tres contribuciones. Primero, llevamos cada política a un perfil completo de siete resultados sobre una población común de parcelas. Segundo, derivamos dominancia uniforme y regiones de cambio sobre una base normalizada predeklarada de seis celdas, sin seleccionar un punto de pérdida favorable. Tercero, hacemos auditable la comparación: los puntos de operación se fijan con entrenamiento y validación, la incertidumbre se agrupa por parche y permanecen visibles las distribuciones de resultados y la sensibilidad a semillas.

La afirmación resultante es deliberadamente condicional. Los datos identifican frecuencias de resultado y regiones de pérdida donde se preferiría una política; no identifican preferencias de las partes interesadas. Ambos bancos de parcelas ya habían sido inspeccionados y siguen siendo exploratorios, y la búsqueda registrada no halló otro banco confirmatorio admisible. Por ello no afirmamos transporte ni hacemos una recomendación universal: este artículo es un atlas de

decisión reproducible que muestra dónde cambia la respuesta, no la afirmación de que una política sea mejor en todas partes.

2. Trabajo relacionado

Organizamos el trabajo previo por la limitación que deja abierta nuestra comparación.

Decisiones con rechazo y conjuntos. La regla óptima de error-rechazo de Chow trata el silencio como alternativa a una etiqueta [5]; Ha amplía la elección a subconjuntos de clases [12]. Mortier et al. optimizan utilidad esperada como función del tamaño del conjunto [17], mientras Chzhen et al. sistematizan estas formulaciones y sus compromisos [6]. La regla selectiva de Ha es una familia parametrizada implementada que no formó parte de los seis brazos ejecutados; una extensión exploratoria prospectiva fija un miembro derivado de validación sin volver confirmatoria la comparación.

La abstención aprendida está desarrollada y queda fuera por decisión. La clasificación selectiva profunda ofrece garantías y rechazadores aprendidos [7,8], pérdidas de tipo apuesta [15] y selección basada en AUC [18]. No los reimplemamos ni comparamos contra ellos: contrastamos una abstención fija con otras tres familias de salida. La cuestión abierta está entre acciones, no en aprender un rechazador mejor.

Cobertura, riesgo y rechazo parcial. La clasificación conforme adaptativa busca cobertura marginal y condicional aproximada [20]; RAPS regulariza etiquetas improbables para reducir el conjunto a cobertura fija [1]. Los conjuntos con control de riesgo certifican una pérdida acotada que especifica el usuario a un nivel elegido [3]. Las opciones de rechazo parcial optimizan desde una etiqueta firme hasta conjuntos y rechazo completo bajo una recompensa dada [14]. Cada método fija cobertura o una especificación de pérdida dentro de una familia. Nosotros dejamos sin especificar las seis coordenadas de pérdida y reportamos dónde cambia la preferencia entre familias.

Observación terrestre y mapeo de cultivos. El precedente más cercano rechaza píxeles inciertos en PASTIS y hace explícito el compromiso entre precisión y recobrado [19], pero no compara familias de salida ni sus fronteras en el espacio de pérdidas. Estudios afines tratan peligros naturales [11], vegetación aerotransportada [10] o detección de cultivos desconocidos [4]. El tamaño del catálogo ya se mide como variable de diseño de cobertura del suelo [9]; por tanto, no inventamos su reducción. Del mismo modo, preceden a nuestro retroceso las jerarquías de cultivos guiadas por confianza [23], la fusión jerárquica [2] y los conjuntos jerárquicos [16]. Nuestra contribución es la cuenta común de resultados para comparar esas acciones establecidas.

Distribución y novedad acotada. La clasificación selectiva puede amplificar disparidades entre grupos [13]; usamos ese resultado para motivar la cuenta por clases, no como evidencia sobre cultivos. Dentro de nuestra búsqueda, no encontramos un trabajo que compare reducción de catálogo, abstención por parcela, predicción por conjuntos y retroceso taxonómico como acciones de un solo problema sobre una base predeclarada de seis celdas. La afirmación cubre 61 consultas automáticas y 6 manuales en inglés, en arXiv, OpenAlex y Semantic Scholar entre 2019–2026, más clásicos recuperados por nombre. No es exhaustiva: las actas de teledetección sin DOI se indexan mal y nuestro vocabulario de clasificación selectiva no encontró el precedente más cercano, que apareció por otra vía.

3. Problema y estimando

3.1. Un solo espacio de acciones

Sea $\mathcal{Y}$ el catálogo de hojas, x_i las observaciones de la parcela i y $y_i \in \mathcal{Y}$ su etiqueta de referencia. Toda política evaluada devuelve

$$C_m(x_i) \subseteq \mathcal{Y}, \quad C_m(x_i) = \emptyset \text{ permitido.} \quad (1)$$

Reducción de catálogo. Un subcatálogo se fija una vez; la política calla cuando el máximo posterior sin restringir queda fuera.

Abstención por parcela. El máximo se emite solo por encima de una confianza fija.

Predicción por conjuntos. Se emite un prefijo posterior no vacío y calibrado.

Retroceso taxonómico. Se emiten las hojas bajo un nodo nombrado. Las políticas difieren en qué subconjuntos admiten y qué los fija, no en su tipo de salida. Dos elementos degenerados acotan el mismo espacio: el singleton de catálogo completo es la referencia evaluada y la no entrega universal es solo una condición de frontera.

3.2. Perfil de resultados y espacio de pérdidas

Fijemos banco, región, campaña, partición, predictor y política m en el punto de operación τ_m . Un mapa predeclarado π asigna cada entrega parcelaria a uno de siete resultados mutuamente excluyentes: entrega precisa correcta o incorrecta, no entrega, conjunto que contiene o excluye la verdad, o respuesta gruesa que la contiene o excluye. La entrega precisa correcta es la referencia de pérdida cero R_0 ; las demás celdas son $L_1, \dots, L_6$. El objeto empírico es el perfil completo

$$q_{m,j} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{O_i(m) = L_j\}, \quad j = 1, \dots, 6, \quad (2)$$




Figura 2. Todas las políticas devuelven subconjuntos de un mismo catálogo de hojas y admiten el conjunto vacío. Las celdas son estructurales: no representan clases ni frecuencias medidas.

donde N incluye toda parcela elegible, también las no entregadas. Un denominador restringido a entregas permitiría mejorar contestando menos.

Para toda pérdida finita no negativa y constante dentro de estas seis celdas, una escala positiva común no altera el orden. Usamos por ello

$$\ell \in \Delta^5 = \{\ell \in \mathbb{R}_+^6 : \sum_j \ell_j = 1\}, \quad R_m(\ell) = \mathbf{q}_m^\top \ell. \quad (3)$$

La base conserva a propósito el tipo de promesa, pero olvida distinciones dentro de una celda, como la cardinalidad, la profundidad taxonómica o qué cultivo erróneo se nombró. El tamaño esperado es un descriptor, no la pérdida común: cobra igual conjuntos del mismo tamaño con distinto contenido y asigna tamaño cero al vacío. Un uso que cobre las distinciones olvidadas necesita ampliar la base.

Los datos determinan $\mathbf{q}$, no ℓ . La política m domina uniformemente a n si $q_{m,j} \leq q_{n,j}$ en cada celda de coste y al menos una desigualdad es estricta. De lo contrario, su frontera de cambio es $(\mathbf{q}_m - \mathbf{q}_n)^\top \ell = 0$. Un plano dibujado fija las demás coordenadas: es una sección de sensibilidad, no el simplex completo ni una regla numérica independiente del contexto.

Los puntos de operación se ajustan solo con entrenamiento y validación. Las etiquetas de evaluación entran cuando ya existen todas las entregas; ni umbrales ni tasas objetivo se vuelven a igualar en el bloque retenido.

3.3. Alcance y dependencia

El estimando está condicionado a cada banco, región, campaña, partición y predictor. La unidad observacional es la parcela y el clúster de dependencia es el parche de imagen. La incertidumbre primaria remuestrea parches completos dentro del bloque espacial retenido; una sensibilidad aparte reparte de nuevo los mismos parches y reejecuta la familia completa. Con menos de tres clústeres pareados únicos, los perfiles quedan descriptivos y no se afirma intervalo ni dominancia.

Los bancos nunca se agregan. El segundo es un contraste descriptivo de región externa, no otra réplica del primero, y las subdivisiones espaciales son agrupaciones de sensibilidad, no territorios independientes. En consecuencia, no afirmamos transporte geográfico: cada resultado se limita al banco y diseño nombrados.

4. Políticas fijas como acciones alternativas

El análisis principal instancia puntos fijos de cuatro familias postentrenamiento como seis brazos. No cubren la retícula: las cascadas cambian información y cómputo, los umbrales por clase añaden parámetros ajustados en validación y los rechazadores aprendidos cambian el entrenamiento. Las políticas aprendidas, adaptativas por clase y multietapa quedan fuera; la afirmación se restringe a estos cuatro puntos y dos ordenamientos de catálogo. La regla selectiva de Ha es una familia parametrizada implementada, pero no perteneció a los seis brazos ejecutados. Una extensión exploratoria prospectiva fija por modelo y estrato un miembro derivado de validación en el menor segundo posterior que alcanza su objetivo singleton; es diagnóstico, no una prueba de admisión.

4.1. Interfaz común y operadores fijos

Cada brazo devuelve un vector booleano de pertenencia sobre el mismo catálogo de hojas. Una entrada verdadera es una entrega precisa, varias forman una entrega ambigua o gruesa y una fila falsa es no entrega. La representación no contiene la etiqueta de referencia ni un filtro de entregas, por lo que las parcelas rechazadas no pueden desaparecer antes de evaluarse.

La línea base emite el máximo posterior. Cada brazo de catálogo conserva un prefijo distinto, predeclarado desde entrenamiento, y emite el máximo sin restringir solo cuando pertenece a ese prefijo. La abstención aplica un umbral derivado de validación. Los conjuntos adaptativos ordenan etiquetas por posterior y emiten el menor prefijo no vacío que alcanza una masa calibrada. La calibración usa el rango conforme exacto $\lceil (n_{\text{cal}} + 1)(1 - \alpha) \rceil$; un rango que supera

la muestra produce el catálogo completo. La construcción es determinista y la contención retenida se reporta, no se usa para recalibrar.

El retroceso taxonómico conserva el singleton confiable y, de lo contrario, emite las hojas representadas bajo un nodo HCAT4 predeclarado. El mapeo resuelve cada hoja y corte contra EuroCrops, y rechaza asignaciones ausentes, repetidas, no ancestrales o fuera del catálogo. Un nodo con una sola hoja representada sigue siendo singleton; no se ensancha después de observar resultados.

Catálogos, umbrales, masas calibradas y cortes jerárquicos son entradas. El ajuste recibe entrenamiento y validación, pero no evaluación; la aplicación recibe posteriores de evaluación, pero no etiquetas; solo el evaluador recibe etiquetas cuando ya existen todas las matrices. Un punto ajustado guarda identidades y rechaza solapamientos entre entrenamiento y validación o su reutilización al evaluar, también si las filas son copias. La invariancia a las etiquetas pertenece al operador y la disyunción de particiones se exige en la orquestación.

El catálogo de hojas sigue la salida del modelo. Un universo neutral se selecciona una vez por soporte de entrenamiento; las etiquetas de validación y evaluación no pueden cambiarlo. Todos los brazos conservan todas las parcelas elegibles en el denominador. Una clase seleccionada pero ausente en evaluación sigue visible con soporte cero y estadística indefinida, sin desaparecer ni convertirse en un cero válido.

4.2. Cuenta cerrada de resultados

El evaluador asigna cada parcela a una sola de las siete celdas de la Sección 3.2, según la entrega visible. Un singleton del brazo de conjuntos es una respuesta precisa; una salida multietiqueta sigue separada de una categoría gruesa nombrada; una fila vacía es no entrega en cualquier brazo. Las dos celdas de fallo no singleton impiden cobrar conjuntos y respuestas gruesas solo cuando contienen la verdad.

La interfaz primaria devuelve el vector completo y no acepta un punto de pérdida. Una interfaz de sensibilidad aparte admite seis pérdidas finitas no negativas, fija en cero la entrega precisa correcta y rechaza mapeos incompletos. Los puntos sintéticos verifican que cambiar precios relativos puede invertir la acción preferida; no son preferencias empíricas. El tamaño esperado del conjunto sigue siendo descriptivo y no ordena los brazos.

5. Protocolo de evaluación

5.1. Bancos, particiones y políticas fijas

Usamos PASTIS-R óptico [22] y BreizhCrops [21]. La cohorte elegible del fold cinco de PASTIS-R contiene 16640 parcelas. Sus cuatro clases principales reúnen 72.0 % y las seis más raras 6.5 %. Son recuentos de parcelas, no proporciones de área; la Fig. 3 es esquemática.

Casi todo el mosaico son cuatro cultivos
una celda = una parcela; posición esquemática




Figura 3. Soporte exacto de clases en la cohorte elegible del fold cinco de PASTIS-R. Cada microcelda es una parcela; posición y forma no tienen significado geográfico ni de área.

Entrenamiento fija el universo de clases y los ordenamientos de catálogo; validación fija los demás puntos de operación. Identidades estables exigen disyunción antes de evaluar. El tamaño del catálogo es el menor prefijo por soporte que alcanza masa acumulada 0,9; la abstención busca 0,9 de entrega, el conjunto adaptativo usa 0,1 de error de cobertura, el retroceso busca 0,9 de hojas precisas y el universo neutral exige 20 parcelas de entrenamiento. Son intervenciones elegidas por los autores, no puntos de pérdida igual, y nunca se reajustan en evaluación.

Los brazos se emparejan por identidad, bloque y `patch_id`; se permite reordenar, no omitir, duplicar ni sustituir. Ambos bancos ya habían sido inspeccionados y siguen exploratorios. Un registro cerrado no admitió un banco confirmatorio aparte, conclusión acotada a sus candidatos registrados y no a todos los datos públicos.

5.2. Incertidumbre y dominancia simultánea

Para cada par y coordenada, el contraste es el indicador del brazo izquierdo menos su comparador. La vista primaria remuestrea grupos completos de `patch_id` dentro de bloques espaciales, mantiene emparejados todos los brazos y combina bloques con sus proporciones de parcelas. Una vista de sensibilidad pondera igual las medias pareadas por bloque. Con menos de tres unidades pareadas, los deltas quedan descriptivos y no se devuelve intervalo, valor p ni afirmación de multiplicidad.

Cuadro 1. Políticas fijas primarias. Cada una es un punto de operación, no una familia completa.

Política	Fijado antes de evaluar	Respuesta visible
Singleton base	Máximo posterior	Una etiqueta hoja
Catálogo por soporte	Prefijo por soporte de entre- namiento	Etiqueta o silencio
Catálogo por F-score	Mismo tamaño, orden con- gelado	Etiqueta o silencio
Abstención	Umbral de confianza de vali- dación	Etiqueta o silencio
Conjunto adaptativo	Masa conforme dividida	Conjunto no vacío
Retroceso HCAT4	Umbral de validación y je- rarquía	Hoja o clase gruesa

Para un par ordenado, $D_{m,n} = \max_j (q_{m,j} - q_{n,j})$. La dominancia inferencial exige que toda cota simultánea unilateral sea a lo sumo cero y que al menos una sea estrictamente menor. El procedimiento congelado usa $\alpha = 0,05$ familiar, intervalos de 95 %, 9,999 remuestreos pareados por parche, probabilidades con suma de uno y semilla 20260909. El estadístico máximo cubre los 15 pares no ordenados y las 6 coordenadas de coste del estrato. Las comparaciones ausentes no se eliminan después de mirar: retienen la afirmación afectada.

Un error estándar cero suele retener la inferencia. La excepción es estructural: si ninguna acción puede producir un resultado, su diferencia es cero en cada clúster y su cota es el cero exacto. Al menos una coordenada no estructural debe mejorar estrictamente. Cada remuestreo recalcula su propio error por parche centrado en bloque; una afirmación entre predictores debe mantener dirección en todos los predictores predeclarados.

La región ganadora del brazo m intersecta el simplex con $(\mathbf{q}_m - \mathbf{q}_n)^\top \boldsymbol{\ell} \leq 0$ para cada comparador. Las secciones bidimensionales declaran todas las coordenadas fijas y no llevan una medida de probabilidad. Los puntos de pérdida no pueden elegir operaciones, definir la familia primaria ni sostener afirmaciones sobre partes interesadas.

6. Resultados

Reportamos contabilidad exploratoria de resultados, no una preferencia universal. La Tabla 2 comprime el objeto empírico detrás de toda comparación antes de aplicar una pérdida. Sus rangos son componente a componente en el panel fijo de predictores, no un perfil sintético. La Fig. 4 muestra después cada perfil conjunto: la abstención mueve masa de errores precisos al silencio; los conjuntos adaptativos mueven la mayor parte hacia respuestas ambiguas que contienen la verdad; y el retroceso introduce entregas gruesas correctas e incorrectas. Ningún movimiento tiene signo hasta asignar coste a sus celdas.

DeepLabv3+							
singleton	64.9	35.1	0.0	0.0	0.0	0.0	0.0
catálogo soporte	63.4	31.7	4.8	0.0	0.0	0.0	0.0
catálogo F1	63.5	30.7	5.8	0.0	0.0	0.0	0.0
abstención	62.2	26.7	11.1	0.0	0.0	0.0	0.0
conjunto	5.8	0.3	0.0	91.1	2.8	0.0	0.0
retroceso	62.9	28.5	0.0	0.0	0.0	4.3	4.3
SegFormer							
singleton	64.7	35.3	0.0	0.0	0.0	0.0	0.0
catálogo soporte	63.5	33.0	3.5	0.0	0.0	0.0	0.0
catálogo F1	63.2	32.0	4.7	0.0	0.0	0.0	0.0
abstención	61.7	27.0	11.3	0.0	0.0	0.0	0.0
conjunto	5.5	0.1	0.0	92.2	2.2	0.0	0.0
retroceso	62.3	28.5	0.0	0.0	0.0	5.3	3.9
TSViT-Pheno							
singleton	85.8	14.2	0.0	0.0	0.0	0.0	0.0
catálogo soporte	79.9	12.4	7.7	0.0	0.0	0.0	0.0
catálogo F1	77.4	10.5	12.1	0.0	0.0	0.0	0.0
abstención	80.6	7.6	11.8	0.0	0.0	0.0	0.0
conjunto	6.8	0.1	0.0	91.6	1.5	0.0	0.0
retroceso	82.3	9.5	0.0	0.0	0.0	5.0	3.2
TSViT-FullM							
singleton	88.1	11.9	0.0	0.0	0.0	0.0	0.0
catálogo soporte	81.4	10.2	8.4	0.0	0.0	0.0	0.0
catálogo F1	77.1	7.8	15.1	0.0	0.0	0.0	0.0
abstención	81.9	5.5	12.6	0.0	0.0	0.0	0.0
conjunto	6.7	0.1	0.0	91.9	1.3	0.0	0.0
retroceso	84.1	7.3	0.0	0.0	0.0	5.4	3.2
U-Net							
singleton	55.4	44.6	0.0	0.0	0.0	0.0	0.0
catálogo soporte	55.1	43.8	1.1	0.0	0.0	0.0	0.0
catálogo F1	55.3	43.9	0.8	0.0	0.0	0.0	0.0
abstención	52.5	35.3	12.2	0.0	0.0	0.0	0.0
conjunto	2.7	0.3	0.0	90.9	6.1	0.0	0.0
retroceso	53.8	38.5	0.0	0.0	0.0	3.4	4.3
	R0	L1	L2	L3	L4	L5	L6
	correcta						

Figura 4. Perfiles completos de frecuencia en PASTIS-R para cada predictor congelado y política primaria. Las celdas son porcentajes de la misma cohorte con referencia válida. El tono repite la magnitud impresa y no es el único canal. Las columnas contienen la referencia de pérdida cero y las seis celdas con coste de la Sección 3.2.

Cuadro 2. Rangos componente a componente de las frecuencias PASTIS-R en el panel fijo de predictores (porcentaje). R_0 es entrega exacta; L_1 – L_6 son las celdas con coste declaradas. Los extremos varían independientemente: una fila no es un perfil conjunto realizable; el artefacto estructurado identifica cada predictor extremo.

Política	R_0	L_1	L_2	L_3	L_4	L_5	L_6
Singleton	55.4–88.1	11.9–44.6	0.0	0.0	0.0	0.0	0.0
Catálogo por soporte	55.1–81.4	10.2–43.8	1.1–8.4	0.0	0.0	0.0	0.0
Catálogo por F1	55.3–77.4	7.8–43.9	0.8–15.1	0.0	0.0	0.0	0.0
Abstención	52.5–81.9	5.5–35.3	11.1–12.6	0.0	0.0	0.0	0.0
Conjunto adaptativo	2.7–6.8	0.1–0.3	0.0	90.9–92.2	1.3–6.1	0.0	0.0
Retroceso taxonómico	53.8–84.1	7.3–38.5	0.0	0.0	0.0	3.4–5.4	3.2–4.3

Para los 5 predictores congelados de PASTIS-R, el atlas primario no certificó dominancia: 71 de 75 pares de acciones fueron ciertamente incomparables y 4 quedaron indeterminados, no empatados. La ausencia de dominancia se mantuvo en las diez semillas. El hallazgo histórico de que ninguna partición espacial fue seleccionada falló en todas las semillas y se retira; sin perfiles de selección por semilla no reportamos reemplazo.

No existe un punto de pérdida prerregistrado que marcar: seleccionar uno está prohibido. En las secciones planas declaradas, la línea base singleton, los conjuntos adaptativos, la abstención y el retroceso taxonómico ganaron en algún lugar; ninguna política de catálogo ganó un punto muestreado. Esto establece cambios en la rejilla declarada, no una probabilidad de ser mejor ni un volumen del simplex.

La Fig. 5 muestra la primera sección de la enumeración exhaustiva, con $L_4 = L_5 = L_6 = 0,1$ y sin agrupar predictores. Se eligió para mostrarla después de materializar, no fue prerregistrada. Las 20 secciones bidimensionales declaradas contienen 66 puntos de rejilla cada una y siguen disponibles en el artefacto estructurado.

La masa conforme y el umbral preciso HCAT4 se ajustaron en validación. Ambas entregas quedaron fijadas antes de abrir las etiquetas de evaluación; la disponibilidad de referencias solo restringió entregas ya fijadas de PASTIS-R. Sus objetivos de validación son restricciones distintas, no una pérdida igual.

Cuadro 3. Alcance inferencial por banco. Los papeles están congelados y los bancos nunca se agregan.

Banco	Papel permitido	Evidencia usada aquí
PASTIS-R	Exploratorio	Perfiles condicionados al banco y atlas por parches
BreizhCrops	Solo descriptivo	Perfiles de región externa; un clúster por estrato modelo–región, sin intervalos pareados




Figura 5. Regiones de ganador cierto en una sección declarada del atlas exploratorio PASTIS-R. Los símbolos identifican la acción ganadora; las cruces son evaluaciones donde la banda simultánea no establece una. Cada panel es un predictor congelado. Las acciones de restricción del catálogo permanecen en la leyenda aunque ninguna gane en esta sección, cerrando la cuenta de seis acciones. La sección mostrada es la primera de la enumeración congelada y fue elegida para presentación después de obtener resultados.

Cada fila conforme cumplió su objetivo marginal, pero devolviendo respuestas múltiples. HCAT4 recuperó entregas adicionales que contenían la verdad en cada fila, pero también emitió respuestas gruesas incorrectas en cada una. Su tasa precisa realizada varió entre estratos pese a un objetivo único de validación. Una clase gruesa nombrada no es rescate gratuito ni el mismo objeto que un conjunto arbitrario que contiene la verdad.

La calibración conforme marginal no implicó cobertura condicional por clase: una clase U-Net de PASTIS-R contuvo la verdad en 28 de 206 conjuntos. El soporte extremo histórico en BreizhCrops fue 6 parcelas; los extremos por semillas abarcaron 1–6 y no sostienen generalización por clase.

Las filas usan cohortes de evaluación con referencia válida: 16640 parcelas PASTIS-R y 30000 parcelas BreizhCrops por región externa. Las otras 11892 identidades posteriores de PASTIS-R no tienen una referencia semántica válida para esta cuenta. La entrega se fijó antes de aplicar ese filtro, por lo que este no

puede mejorar su tasa; esas identidades tampoco se describen en silencio como parcelas evaluadas.

Juntos, perfiles y atlas responden la pregunta más estrecha que permiten los datos: qué política se prefiere para una pérdida declarada sobre seis celdas y dónde cambia esa preferencia. No identifican la pérdida misma.

7. Discusión

Los diagnósticos muestran por qué una sola tasa de éxito no responde a la pregunta de decisión. Los conjuntos conformes logran contención marginal al devolver varias etiquetas; HCAT4 a veces recupera la verdad mediante un padre comunicable y a veces devuelve el padre equivocado. Declarar que cualquiera es uniformemente mejor pondría de forma implícita precio cero a la amplitud o al error grueso, por lo que las coordenadas de resultado deben permanecer separadas.

La afirmación de cobertura está condicionada a cada banco evaluado y a la intercambiabilidad entre sus parcelas de calibración y evaluación. Ambos bancos ya habían sido inspeccionados antes de esta ejecución, de modo que todos los resultados son exploratorios aunque las particiones de evaluación se mantengan fuera de la calibración. No se deriva ninguna afirmación de transporte, y la búsqueda cerrada no halló otro banco confirmatorio admisible. La variación entre predictores es sensibilidad, no una vía para seleccionar un modelo favorable. PASTIS-R sostiene por ello un atlas de decisión exploratorio; BreizhCrops sostiene perfiles descriptivos, pero no inferencia pareada, porque su estructura de reporte congelada tiene solo 1 clúster por estrato modelo-región.

La ausencia de dominancia certificada no es un empate: los perfiles que se cruzan y las victorias de cuatro acciones rechazan un orden independiente del precio y localizan sus cambios. Que la restricción del catálogo no gane ningún punto muestreado no prueba que sus regiones tengan volumen cero, pues la rejilla no define una medida sobre el simplex. La conclusión sobre agrupamiento espacial cambió bajo la rejilla congelada de semillas; la retiramos en vez de elegir una partición favorable después de observar el atlas.

Dos restricciones de alcance son esenciales. Primero, cada brazo es una política de operación fija; el estudio no ordena cada miembro posible de su familia. Segundo, la cuenta de seis celdas olvida a propósito cardinalidad del conjunto, profundidad taxonómica y qué par de cultivos fue confundido. Un uso que cobre cualquiera de esas distinciones necesita ampliar la base antes de aplicar la misma geometría.

Los checkpoints heredados de PASTIS-R no registran semillas de entrenamiento en sus fuentes de identidad. La sensibilidad a semillas solo puede reejecutar etapas estocásticas posteriores al entrenamiento para esos miembros; no establece robustez frente a la aleatoriedad de entrenamiento. No rellenamos esa afirmación reentrenando después de observar el atlas. Se conservan los predichos estables; los conteos que cambiaron se reportan como rangos. El muestreo y

los ajustes clásicos de BreizhCrops siguen siendo reejecutables y separados, sin agregarlos.

La robustez al ruido de etiqueta tampoco está medida: no se declaró un modelo de transición entre clases específico de cada banco y la familia secundaria retenida no aporta un objetivo estimable de corrupción. Por ello no inyectamos un proceso sintético conveniente después de ver los resultados.

Disponibilidad de datos y código

El archivo fuente anónimo contiene el proyecto $\text{\LaTeX}$, la bibliografía, el apéndice generado y las figuras, pero no datos satelitales crudos. Un suplemento anónimo separado reconstruye los setenta y cinco veredictos pareados del atlas y la rejilla declarada desde recuentos agregados por parche; no incluye imágenes, registros por parcela, acceso al repositorio ni metadatos de autoría. Los artefactos de entrenamiento permanecen privados durante la revisión y acompañarán un archivo citable antes de la publicación. Los datos fuente conservan las condiciones de sus proveedores; quienes repliquen el trabajo reejecutarán el atlas y las figuras desde conteos de resultados, no desde las imágenes.

Referencias

1. Angelopoulos, A., Bates, S., Malik, J., Jordan, M.I.: Uncertainty sets for image classifiers using conformal prediction (2020)
2. Barriere, V., Claverie, M., Schneider, M., Lemoine, G., d’Andrimont, R.: Boosting crop classification by hierarchically fusing satellite, rotational, and contextual data. *Remote Sensing of Environment* **305**, 114110 (2024). <https://doi.org/10.1016/j.rse.2024.114110>
3. Bates, S., Angelopoulos, A., Lei, L., Malik, J., Jordan, M.: Distribution-free, risk-controlling prediction sets. *Journal of the ACM* (2021). <https://doi.org/10.1145/3478535>
4. Carvalho, T., Martinez, J.A.C., Oliveira, H., dos Santos, J.A., Feitosa, R.Q.: Outlier exposure for open set crop recognition from multitemporal image sequences. *IEEE Geoscience and Remote Sensing Letters* **20**, 1–5 (2023). <https://doi.org/10.1109/LGRS.2023.3244532>
5. Chow, C.: On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory* (1970). <https://doi.org/10.1109/tit.1970.1054406>
6. Chzhen, E., Denis, C., Hebiri, M., Lorieul, T.: Set-valued classification — overview via a unified framework (2021)
7. Geifman, Y., El-Yaniv, R.: Selective classification for deep neural networks. In: *Advances in Neural Information Processing Systems* 30 (NIPS 2017). pp. 4878–4887. Curran Associates (2017), <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>
8. Geifman, Y., El-Yaniv, R.: SelectiveNet: A deep neural network with an integrated reject option. In: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. *Proceedings of Machine Learning Research*, vol. 97, pp. 2151–2159. PMLR (2019), <https://proceedings.mlr.press/v97/geifman19a.html>

9. Ghassemi, B., Izquierdo-Verdiguier, E., d'Andrimont, R., Vuolo, F.: How accurately and in what detail can land use and land cover be mapped using copernicus Sentinel and LUCAS 2022 data? *Remote Sensing* **17**(8), 1379 (2025). <https://doi.org/10.3390/rs17081379>
10. Gimenez, R., Laloue, A., Fabre, S.: Rejection methods for vegetation mapping using hyperspectral airborne data. *International Journal of Remote Sensing* **44**(16), 4937–4962 (2023). <https://doi.org/10.1080/01431161.2023.2240520>
11. Gonzalez-Calabuig, M., Cohrs, K.H., Nedungadi, V., Osika, Z., Cartuyvels, R., Knoblauch, S., Massant, J., Nath, S., Ebel, P., Sitokonstantinou, V.: SHRUG-FM: Reliability-aware foundation models for Earth observation. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*. pp. 7919–7928 (2026)
12. Ha, T.M.: The optimum class-selective rejection rule. *IEEE Transactions on Pattern Analysis and Machine Intelligence* **19**(6), 608–615 (1997). <https://doi.org/10.1109/34.601248>
13. Jones, E., Sagawa, S., Koh, P.W., Kumar, A., Liang, P.: Selective classification can magnify disparities across groups. In: *9th International Conference on Learning Representations (ICLR)* (2021), https://openreview.net/forum?id=NOM_4BkQ05i
14. Karlsson, M., Hössjer, O.: Classification under partial reject options. *Journal of Classification* (2023). <https://doi.org/10.1007/s00357-023-09455-x>
15. Liu Ziyin, Wang, Z., Liang, P.P., Salakhutdinov, R., Morency, L.P., Ueda, M.: Deep gamblers: Learning to abstain with portfolio theory. In: *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. pp. 10622–10632. Curran Associates (2019), <https://proceedings.neurips.cc/paper/2019/hash/0c4b1eeb45c90b52bfb9d07943d855ab-Abstract.html>
16. Mortier, T., Hüllermeier, E., Dembczyński, K., Waegeman, W.: Set-valued prediction in hierarchical classification with constrained representation complexity. In: *Proceedings of the Thirty-Eighth Conference on Uncertainty in Artificial Intelligence. Proceedings of Machine Learning Research*, vol. 180, pp. 1392–1401. PMLR (2022), <https://proceedings.mlr.press/v180/mortier22a.html>
17. Mortier, T., Wydmuch, M., Dembczyński, K., Hüllermeier, E., Waegeman, W.: Efficient set-valued prediction in multi-class classification. *Data Mining and Knowledge Discovery* **35**, 1435–1469 (2021). <https://doi.org/10.1007/s10618-021-00751-x>
18. Pugnana, A., Ruggieri, S.: AUC-based selective classification. In: *Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS)*. *Proceedings of Machine Learning Research*, vol. 206, pp. 2494–2514. PMLR (2023), <https://proceedings.mlr.press/v206/pugnana23a.html>
19. Rey, M., Mnih, A., Neumann, M., Overlan, M., Purves, D.: Uncertainty evaluation of segmentation models for Earth observation (2025)
20. Romano, Y., Sesia, M., Candès, E.J.: Classification with valid and adaptive coverage (2020)
21. Rußwurm, M., Pelletier, C., Zollner, M., Lefèvre, S., Körner, M.: BreizhCrops: A time series dataset for crop type mapping. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences* **XLIII-B2-2020**, 1545–1551 (2020). <https://doi.org/10.5194/isprs-archives-XLIII-B2-2020-1545-2020>
22. Sainte Fare Garnot, V., Landrieu, L., Chehata, N.: Multi-modal temporal attention models for crop mapping from satellite time series. *ISPRS Journal of Photogram-*

- metry and Remote Sensing **187**, 294–305 (2022). <https://doi.org/10.1016/j.isprsjprs.2022.03.012>
23. Turkoglu, M.O., D’Aronco, S., Perich, G., Liebisch, F., Streit, C., Schindler, K., Wegner, J.D.: Crop mapping from image time series: Deep learning with multi-scale label hierarchies. Remote Sensing of Environment **264**, 112603 (2021). <https://doi.org/10.1016/j.rse.2021.112603>