

¿Cuándo debe decir menos un mapa de cultivos?

Comparación de políticas de salida fijas bajo pérdidas no especificadas

Javier A. Rebull-Saucedo¹[0009-0008-2089-5274]* and Arthur Jafed Zizumbo-Velasco¹[0009-0002-1603-8946]

Tecnológico de Monterrey, Mexico
rebull@exatec.tec.mx, A01796363@tec.mx

Resumen Un clasificador de cultivos no siempre debe emitir una etiqueta hoja: puede reducir su catálogo, abstenerse, devolver un conjunto o retroceder a una categoría agronómica más gruesa. Comparamos políticas fijas posteriores al entrenamiento de esas cuatro familias mediante una sola cuenta de siete resultados. Seis celdas cargan pérdida; la representación es exacta para pérdidas constantes dentro de esta base predeclarada, no para toda utilidad downstream posible. Los puntos de operación se fijan con entrenamiento y validación, y el bloque retenido estima el vector completo de frecuencias de cada política. Esos vectores identifican dominancia uniforme y fronteras lineales sin elegir la pérdida de un usuario. En cinco predictores congelados sobre la cohorte PASTIS-R con referencia válida, ningún par de políticas dentro de un predictor fue certificado como dominante, mientras cuatro tipos de política fueron preferidos en alguna sección de sensibilidad declarada. BreizhCrops aporta perfiles descriptivos, no inferencia pareada bajo la unidad de agrupamiento congelada. El estudio es exploratorio y condicional a los bancos: no afirma transporte geográfico ni una respuesta universalmente óptima a la incertidumbre. Su contribución es mostrar de forma reproducible cuándo la evidencia decide la política y cuándo la decide el coste.

Keywords: Mapeo de cultivos · Clasificación selectiva · Predicción de conjuntos · Teoría de decisión · Series temporales de imágenes satelitales

1. Introducción

Un mapa de cultivos a nivel de parcela es una promesa. Nombra un cultivo para cada campo de la escena, y alguien actúa después con base en ese nombre: un inspector programa una visita, un agrónomo planea un insumo o una agencia liquida un subsidio. Cuando el clasificador duda, responder de todos modos transfiere la incertidumbre a esa persona sin avisarle.

Hay más de una manera de decir menos. El mapa puede *reducir el catálogo* que está dispuesto a prometer y dejar de ofrecer las clases que no separa; puede

* Corresponding author.




Figura 1. Tres parches reales de PASTIS-R en color natural Sentinel-2 y sus etiquetas de referencia por parcela. Los paneles fueron elegidos antes de esta revisión mediante una regla congelada de densidad y variedad de clases; dan contexto visual y no son ejemplos del modelo.

abstenerse para una parcela y derivarla a una persona; puede devolver un *conjunto de etiquetas candidatas* para que el lector elija; o puede *retroceder* a una categoría agronómica más gruesa que sí puede defender. Cada opción compra precisión con una moneda distinta y desplaza el coste a otro lugar.

Prometer menos para equivocarse menos no es una idea nueva. El compromiso error–rechazo se debe a Chow [3]; Ha lo generalizó después a la selección de un *subconjunto* de clases, junto con su criterio de optimalidad [10]. Trabajos recientes dan algoritmos eficientes para el subconjunto de máxima utilidad esperada [14] y sistematizan las formulaciones disponibles [4]. En mapeo de cultivos, el tamaño del catálogo ya se midió como variable de diseño [7]; y el trabajo más cercano rechaza píxeles por incertidumbre en el mismo banco y con tres arquitecturas también representadas en nuestro banco original, haciendo explícito el compromiso entre precisión y recobrado [16].

Lo que no encontramos fue una comparación de políticas fijas de estas familias *entre sí*. Cada línea optimiza su propio dispositivo y reporta su propia curva. Dentro del alcance de búsqueda descrito en la Sección 2, no encontramos un trabajo que reúna reducción de catálogo, abstención, respuestas por conjuntos y retroceso taxonómico en un mismo problema de decisión, conserve la base predeclarada de seis celdas y pregunte qué conclusiones son invariantes a toda pérdida no negativa que sea constante dentro de esas celdas.

Contribución. Formulamos la comparación y las condiciones bajo las cuales puede creerse. En concreto: (i) tratamos políticas fijas de las cuatro familias como *acciones* alternativas de un mismo problema y representamos cada una mediante su vector completo de frecuencias de resultado; (ii) fijamos el estimando, la población y la unidad de análisis *antes* de calcular, y exigimos que cada punto de operación proceda únicamente de entrenamiento y validación; (iii) derivamos dominancia uniforme y fronteras de cambio sobre la base normalizada de seis celdas, en vez de escoger un punto favorable; y (iv) reportamos la distribución de resultados entre clases, pues un mecanismo que mejora un promedio descartando en silencio clases raras ya no mejora el mismo mapa.

Lo que este artículo no afirma. No inferimos de las salidas del modelo las preferencias de una parte interesada ni elegimos un punto de pérdida en su nombre. La evidencia puede identificar dominancia uniforme y la frontera en la que una acción pasa a ser preferible; no puede ubicar en ese espacio a un inspector, asesor o productor concreto. Todo punto externo posterior es una sensibilidad declarada, no una entrada oculta del análisis primario. La búsqueda registrada cerró sin un banco confirmatorio admisible y su log de consultas específico no fue versionado; por ello, la ausencia se limita al conjunto documentado de candidatos y no a toda la literatura. Los dos bancos parcelarios disponibles siguen siendo exploratorios. Los diagnósticos conformes y jerárquicos que siguen no cambian ese papel ni constituyen una comparación terminada de las cuatro acciones.

2. Trabajo relacionado

Organizamos esta sección por *limitación* y no por aplicación: para cada línea de trabajo decimos qué establece y dónde se detiene, porque ese punto define lo que todavía falta.

El marco de renuncia ya existe. El compromiso error–rechazo y su regla óptima se deben a Chow [3]; esa formulación es el caso degenerado en el que la única alternativa a responder es el silencio. Ha la generalizó al rechazo selectivo por clase y demostró que elegir un subconjunto de clases es el compromiso óptimo entre error y número medio de clases devueltas [10]; el tratamiento es de teoría de decisión y supone conocidas las posteriores. La regla selectiva de Ha es una familia parametrizada implementada. No perteneció a la familia de seis brazos ya ejecutada; una extensión exploratoria prospectiva congela un miembro derivado de validación como séptimo brazo, sin convertirlo en comparación confirmatoria. Mortier et al. dan algoritmos para el subconjunto Bayes-óptimo de máxima utilidad esperada, con una utilidad que depende del tamaño del conjunto [14]; Chzhen et al. unifican las formulaciones y sus compromisos [4], a muestra infinita y bajo un principio de sustitución. El marco no es nuestra contribución. Estos tratamientos comparten que el precio de una respuesta es función de *su tamaño*; no comparan políticas fijas de las cuatro familias con la misma base de seis resultados declarada.

La abstención aprendida está desarrollada y queda fuera por decisión. La clasificación selectiva profunda ofrece garantías de riesgo [5], una arquitectura con cabeza de rechazo integrada [6], una pérdida de tipo apuesta [12] y un criterio de selección basado en AUC [15]. Todas se abstienen *por instancia*; ninguna emite un conjunto ni retrocede a una clase gruesa. No las reimplementamos ni comparamos contra ellas: preguntamos cómo se compara la abstención con las otras tres acciones bajo un espacio común de pérdidas, no si existe una regla de abstención mejor.

La renuncia llegó a observación de la Tierra, pero no desde la agricultura. El trabajo más cercano rechaza píxeles mediante un umbral de incertidumbre en PASTIS, usa tres arquitecturas del banco candidato original y explicita el compromiso: no responder reduce el recobrado y puede elevar la precisión cuando el píxel rechazado habría sido mal clasificado [16]. Es el compromiso riesgo-cobertura, ejecutado y reconocido. No lo sitúa en el marco de clasificación selectiva, no compara acciones alternativas ni caracteriza las fronteras del espacio de pérdidas donde cambia la acción preferida. En otros dominios de observación terrestre, SHRUG-FM reporta abstención con umbrales interpretables [9] para cicatrices de incendio, inundaciones y deslizamientos, no para agricultura. Métodos de rechazo se aplicaron a mapeo de vegetación [8] con datos hiperespectrales aerotransportados, no con series satelitales por parcela. El reconocimiento abierto de cultivos rechaza lo *desconocido* mediante exposición a atípicos [2], una pregunta distinta de repartir el grado de promesa entre clases conocidas.

El tamaño del catálogo ya es una variable de diseño medida. Ghassemi et al. tratan y miden el número de clases como variable de diseño: partiendo de 52 clases LUCAS, un esquema de 26 equilibra precisión y detalle [7]. Es el precedente directo para leer la reducción del catálogo como punto de operación e impide afirmar que somos los primeros. Allí el contexto es cobertura del suelo con Random Forest; aquí es una de cuatro familias de políticas, representada en un vocabulario común sobre la clase de pérdidas inducida por la base declarada de seis celdas.

El retroceso taxonómico ya tiene precedente en mapeo de cultivos. Las jerarquías de etiquetas multiescala mejoran el mapeo desde series temporales satelitales [19]. Ese trabajo predice en tres granularidades y permite que la confianza determine la granularidad de salida; es un precedente directo del retroceso taxonómico guiado por confianza, no solo del entrenamiento jerárquico. La fusión jerárquica también combina señales satelitales, rotacionales y contextuales [1], pero para fusionar información y no para entregar granularidad variable. No reclamamos como nuevo el retroceso. También se formalizó la predicción jerárquica de conjuntos usando nodos internos como conjuntos válidos habituales [13]. La comparación abierta es si esta acción es uniformemente preferible a otra y, de no serlo, dónde está su frontera.

Los efectos distributivos están documentados fuera de nuestro dominio. La clasificación selectiva puede *amplificar* disparidades entre grupos: abstenerse más

puede empeorar sus resultados [11]. La evidencia corresponde a grupos demográficos en visión y lenguaje, no a clases agronómicas o parcelas. La usamos como razón para reportar distribución entre clases, no como evidencia sobre cultivos, y señalamos que contradice la intuición de que negarse a responder sea neutral.

Novedad, con su universo declarado. No encontramos un trabajo que compare reducción de catálogo, abstención por parcela, predicción de conjuntos y retroceso taxonómico *como acciones alternativas del mismo problema*, reporte su orden de dominancia uniforme sobre una base predeclarada de seis celdas y contabilice la distribución de los resultados entre clases. La afirmación está acotada por nuestra búsqueda: arXiv, OpenAlex y Semantic Scholar, 61 consultas automáticas y 6 manuales, entre 2019–2026 más los clásicos recuperados por nombre, solo en inglés. El procedimiento indexa mal las actas de teledetección sin DOI y usa el vocabulario de clasificación selectiva; observamos este sesgo porque el trabajo más cercano [16] no emplea esos términos y apareció por otra vía.

3. Formulación del problema y estimando

3.1. Cuatro maneras de prometer menos

Sea $\mathcal{Y}$ el catálogo de clases, x_i las observaciones de la parcela i y $y_i \in \mathcal{Y}$ su etiqueta de referencia. Un clasificador convencional se compromete con un mapeo $x_i \mapsto \hat{y}_i \in \mathcal{Y}$: debe nombrar exactamente una clase para cada parcela, sin importar la forma de su posterior. Todos los mecanismos comparados relajan ese compromiso de la misma manera formal. Sustituyen la predicción puntual por un subconjunto,

$$C_m(x_i) \subseteq \mathcal{Y}, \quad C_m(x_i) = \emptyset \text{ permitido}, \quad (1)$$

y solo difieren en los subconjuntos que pueden emitir y en qué fija la elección.

Reducción del catálogo. Se fija un subcatálogo $\mathcal{S} \subset \mathcal{Y}$ antes de observar parcelas. Si el máximo de la posterior sin restricciones cae dentro de $\mathcal{S}$, se entrega el máximo restringido; si cae fuera, no se entrega nada. La regla lee la posterior, no la etiqueta de referencia: condicionar la entrega a la verdad haría imposible el mecanismo durante la inferencia, aunque una implementación anterior hizo exactamente eso. La decisión se toma una vez por clase.

Abstención por parcela. Se emite un singleton o el conjunto vacío según si una medida de confianza supera un punto de operación. La decisión se toma por parcela.

Predicción de conjuntos. Se emite un subconjunto no vacío cuyo tamaño cambia con la dificultad de la parcela y se calibra hacia una meta nominal de contención marginal. Toda garantía finita requiere además intercambiabilidad entre calibración y evaluación; reportamos la contención observada y no afirmamos que el remuestreo espacial repare ese supuesto. Toda parcela recibe respuesta; cambia cuánto se compromete esa respuesta.




Figura 2. Las políticas evaluadas comparten un tipo de salida: un subconjunto del catálogo de hojas, incluido el conjunto vacío. El diagrama es estructural; sus celdas no representan clases ni frecuencias medidas.

Retroceso taxonómico. Se emite el conjunto de hojas bajo un nodo de una jerarquía de clases. Formalmente es otro subconjunto; lo distingue que los subconjuntos admisibles son categorías que un agrónomo puede nombrar, de modo que la respuesta baja a una categoría más gruesa pero comunicable, no a una lista arbitraria.

Dos elementos degenerados delimitan el mismo espacio: la predicción singleton sobre el catálogo completo, que no renuncia a nada, y la no entrega universal, con $C \equiv \emptyset$. Ninguno es un mecanismo, pues ninguno elige a qué renunciar. Tampoco ocupan el mismo papel: la línea base sí se evalúa como referencia para poner precio a toda renuncia; la no entrega universal solo fija la frontera del precio del silencio y nunca se ejecuta. Escribir todo en un mismo espacio de acciones permite formular la pregunta: mientras diseño de leyenda, umbrales, calibración conforme y predicción jerárquica sean técnicas separadas, no existe un objeto común sobre el que preguntar cuál se debe preferir.

3.2. El estimando

Fijemos un banco d con su región, campaña, partición y predictor, y una política m que opera en τ_m . Su objeto realizado completo es $Z_{i,m} = (y_i, C_m(x_i), a_m)$,

donde a_m registra si una respuesta no singleton es un conjunto arbitrario o una categoría taxonómica nombrada. Una proyección predeclarada $\pi(Z)$ lleva ese objeto a una celda de una cuenta cerrada: entrega precisa correcta, entrega precisa incorrecta, no entrega, conjunto que contiene o excluye la verdad, o respuesta gruesa que contiene o excluye la verdad. La entrega precisa correcta es la referencia de pérdida cero R_0 ; las demás celdas son $L_1, \dots, L_6$. La cantidad empírica es su vector de frecuencias,

$$q_{d,m,j} = \frac{1}{N_d} \sum_{i=1}^{N_d} \mathbf{1}\{O_i(m) = L_j\}, \quad j = 1, \dots, 6, \quad (2)$$

donde N_d cuenta *todas* las parcelas elegibles del bloque. Para toda pérdida finita no negativa constante dentro de las seis celdas con coste de π , una escala positiva común no cambia el orden; normalizamos entonces

$$\ell \in \Delta^5 = \left\{ \ell \in \mathbb{R}_+^6 : \sum_{j=1}^6 \ell_j = 1 \right\}, \quad R_{d,m}(\ell) = \mathbf{q}_{d,m}^\top \ell. \quad (3)$$

La representación es exacta para la clase declarada $L_\ell(Z) = \ell_{\pi(Z)}$, con pérdida cero en R_0 . No es completa para toda utilidad downstream: dos conjuntos que contienen la verdad pero tienen tamaños distintos ocupan la misma celda, igual que dos etiquetas agrícolas erróneas con consecuencias diferentes. La uniformidad siguiente se refiere a la base de seis celdas, no a todo uso concebible del mapa.

Los datos determinan $\mathbf{q}$, no ℓ . Reportamos por ello la geometría lineal completa en vez de insertar un punto. El brazo m domina uniformemente a n exactamente cuando $q_{m,j} \leq q_{n,j}$ en toda celda con coste y al menos una desigualdad es estricta. Si no, su frontera de cambio es el hiperplano $(\mathbf{q}_m - \mathbf{q}_n)^\top \ell = 0$. Un precio escalar solo existe dentro de una sección declarada que fija las demás coordenadas. Una figura bidimensional es una vista de sensibilidad, no todo el simplex inducido por la base declarada.

La cardinalidad no es la pérdida. El tamaño esperado cobra igual dos conjuntos de igual tamaño aunque uno excluya la verdad y asigna tamaño cero a la no entrega. Lo conservamos como descriptor, nunca como objetivo común. Tampoco inferimos un punto de pérdida de las salidas: eso convertiría una preferencia de modelado en resultado de datos. Un punto externo posterior puede superponerse como sensibilidad no confirmatoria, declarando su procedencia.

La población incluye las parcelas sin entrega. N_d recorre toda parcela elegible, incluidas las que el mecanismo no responde y aquellas cuya clase dejó de pertenecer al catálogo reducido. Restringir el denominador a entregas pondría precio cero a la renuncia y evaluaría cada mecanismo en una población que él mismo elige, permitiéndole mejorar al responder menos.

El punto de operación se fija antes de tocar el bloque retenido. τ_m se deriva íntegramente de entrenamiento y validación. El bloque retenido estima el resultado realizado y nada más. Se prohíbe reigualar pérdida, cobertura o tasa de entrega en ese bloque, incluso como ajuste posterior para hacer comparables los mecanismos: es la fuga que dos auditorías encontraron en una versión anterior, primero en el umbral y después en su tasa objetivo.

3.3. Alcance, dependencia y afirmaciones excluidas

La inferencia es *condicional a cada banco*, con su región, campaña, partición y predictor. La unidad observacional es la parcela. Las parcelas no son independientes: llegan en parches que comparten adquisición, geografía y anotación; por ello el clúster es el parche. El bootstrap remuestrea parches completos dentro de bloques espaciales y nunca parcelas individuales. El atlas primario de PASTIS-R trata su fold externo retenido como un estrato y remuestrea sus parches. Una sensibilidad separada reparte esos mismos parches en cada k declarado y reejecuta toda la familia; no elimina parcelas ni convierte subdivisiones en territorios independientes. Con menos de tres clústeres pareados únicos, el perfil se reporta de forma descriptiva sin inferencia, pues el intervalo describiría el esquema de remuestreo y no los datos.

No se agrupa ninguna cantidad entre bancos. Cada uno se reporta por separado; el segundo ofrece un contraste descriptivo de región externa y no otra muestra del primero. El número de bloques es un parámetro de sensibilidad para agrupar la misma evidencia, no un número de réplicas ni una palanca de potencia estadística.

Lo que el diseño sacrifica se declara aquí porque limita cada afirmación posterior: **no afirmamos transporte**. Nada observado en una región o campaña se supone válido en otra. El estimando condicional es lo que permiten las particiones disponibles; uno marginal requeriría una muestra de regiones que no tenemos. Una versión anterior mezcló ambos hasta que la auditoría los separó.

Ninguna geografía de despliegue forma parte de la afirmación científica. Las regiones evaluadas solo sostienen conclusiones condicionales a sus bancos; aplicar la comparación en otro lugar exige nuevas referencias y un diseño prospectivo de evaluación.

4. Políticas fijas como acciones alternativas

El análisis principal materializa puntos fijos de cuatro familias posteriores al entrenamiento como seis brazos: línea base, dos ordenamientos del catálogo, abstención, predicción de conjuntos y retroceso taxonómico. No cubren todo el retículo. Las cascadas cambian información y cómputo; los umbrales por clase añaden parámetros escasos ajustados en validación; los rechazadores aprendidos cambian el entrenamiento. Las políticas aprendidas, adaptativas por clase y multitapa siguen sin explorarse; las afirmaciones se limitan a estos cuatro puntos y

a los dos ordenamientos. La no entrega universal es una frontera. Por combinación modelo–estrato, la extensión prospectiva de Ha fija su coste en la segunda posterior más alta mínima de validación que alcanza el objetivo singleton, sin etiquetas retenidas ni reigualación; sin banco confirmatorio, es diagnóstico y no prueba de admisión.

4.1. Un tipo de salida común

Cada brazo devuelve el vector booleano de pertenencia de $C_m(x_i)$ sobre el catálogo fijo. La representación no contiene etiqueta de referencia, pérdida ni filtro de solo entregas. Una fila con un verdadero es una entrega precisa; con varios, una entrega ambigua o gruesa; toda falsa es no entrega. Mantener el conjunto vacío dentro del tipo de salida evita que una parcela abstendida desaparezca antes de contarla.

La línea base emite el singleton del máximo posterior. Ambos brazos de reducción aplican el mismo operador a un subcatálogo predeclarado distinto. Si el máximo sin restricciones pertenece al subcatálogo, se emite; si no, la salida es vacía. El operador no mira la referencia. Los brazos solo difieren en la regla de entrenamiento que ordena las clases a retirar, no en el tratamiento de una parcela de prueba.

La abstención emite el máximo cuando su confianza supera un umbral fijo y el vacío en otro caso. La predicción de conjuntos ordena etiquetas por posterior y emite el prefijo no vacío más corto que alcanza una masa acumulada calibrada. El constructor aplica esa masa, pero no la estima: la calibración pertenece a entrenamiento y validación, y cualquier garantía depende de ella.

El brazo de conjuntos usa conjuntos adaptativos split-conformal deterministas y no aleatorizados. Para cada parcela de calibración, la puntuación es la masa posterior acumulada hasta la etiqueta verdadera bajo un orden estable. La masa se selecciona mediante el rango exacto de estadístico de orden finito $\lceil (n_{\text{cal}} + 1)(1 - \alpha) \rceil$, no pasando una fracción de rango a una API de cuantiles que interpola. Si el rango excede la muestra, se emite el catálogo completo y no el mayor puntaje observado. La convención determinista evita otra aleatorización y semilla; su posible conservadurismo se reporta mediante contención marginal y tamaño observado. La afirmación finita usual está condicionada a intercambiabilidad; agrupar parcelas espacialmente no vuelve automático ese supuesto. La cobertura retenida se reporta por ello como contención empírica sobre todas las parcelas y nunca se usa para recalibrar la masa.

El retroceso taxonómico usa un corte HCAT de cuarta edición predeclarado sobre las hojas. Una parcela confiable conserva el singleton; una incierta recibe todas las hojas representadas bajo el nodo que contiene el máximo posterior. El mapeo comprometido resuelve cada hoja y nodo contra la taxonomía EuroCrops antes de predecir, y rechaza asignaciones ausentes, repetidas, no ancestrales o fuera del catálogo. Tres nodos contienen una sola hoja del estudio; retroceder allí deja visible el singleton en vez de saltar después a un nodo más ancho. Una jerarquía mal formada no puede convertir en silencio una parcela en no entrega; una jerarquía más profunda sería otra regla de operación.

Todos los puntos de operación —catálogo retenido, umbral, masa calibrada y partición gruesa— son entradas de los operadores. Ninguno se ajusta dentro de ellos ni puede reiguarse en el bloque retenido. Esta separación vuelve inspeccionable la invariancia a etiquetas: cambiarlas no cambia el conjunto entregado.

La invariancia es propiedad de los operadores; la disyunción de bloques es responsabilidad de quien los llama. Un punto ajustado conserva identidades estables de las filas usadas y se niega a aplicarse sobre cualquiera de ellas. La identidad no se infiere de los bytes de las posteriores: parcelas distintas pueden compartirlas y recalculas la misma parcela puede cambiar sus bytes. Entregar de nuevo el bloque evaluado como calibración falla explícitamente, en lugar de dejar pasar la fuga observada en una versión anterior.

La interfaz impone el orden temporal. El ajuste acepta arreglos de entrenamiento y validación sin argumento de prueba; la aplicación acepta posteriores retenidas sin etiquetas; solo el evaluador recibe etiquetas, cuando ya existen las seis matrices. Una única ruta compone las etapas sin proporcionar valores predeterminados para tamaño de catálogo, entrega, desajuste, retroceso, jerarquía o pérdida. Así, una elección ausente del preregistro no se vuelve un valor por defecto.

El catálogo de hojas viene fijado por la salida del modelo en entrenamiento. Por separado, un universo neutral se selecciona una sola vez desde etiquetas de entrenamiento mediante el piso de soporte. Validación y prueba no añaden ni quitan clases. Cada brazo conserva toda parcela en su denominador, incluidas no entregas y clases fuera del resumen neutral. Una clase seleccionada pero ausente sigue visible con soporte cero y estadístico indefinido; no se elimina ni se convierte en cero válido. Cada frecuencia y diagnóstico usa denominadores fijados antes de observar la entrega.

4.2. La base declarada acción–resultado

La interfaz sigue la proyección cerrada del contrato. Una etiqueta precisa es correcta —referencia de pérdida cero— o incorrecta. El conjunto vacío es no respuesta. Un conjunto con varias etiquetas contiene o excluye la verdad. Una clase gruesa también contiene o excluye la verdad. Son siete celdas. Las dos fallas de respuestas no singleton son indispensables: sin ellas, conjuntos y respuestas gruesas solo pagarían cuando aciertan y adquirirían otra falla gratuita.

La celda se decide por la entrega visible, no por el nombre del algoritmo. Un singleton del brazo de conjuntos se puntúa como etiqueta precisa. Una entrega múltiple se distingue como conjunto libre o clase gruesa nombrada, pues sus consecuencias pueden diferir. Una fila vacía es no respuesta en todo brazo. Cada parcela ocupa exactamente una celda.

El evaluador primario cuenta las siete celdas y devuelve el vector completo sin aceptar un punto de pérdida. Una interfaz separada de sensibilidad acepta seis pérdidas finitas no negativas, mantiene en cero la etiqueta precisa correcta y rechaza mapeos incompletos. Al quitar la escala común, los puntos forman un simplex de cinco dimensiones. Puntos sintéticos prueban que cambiar el precio relativo de error y silencio puede invertir la acción de menor riesgo; no se vuelven

preferencias empíricas. La completitud se refiere a esta cuenta: una utilidad que varíe dentro de una celda requiere una base más rica y queda fuera de la afirmación de dominancia.

Cada frecuencia usa el mismo denominador de la Ec. (2), incluidas las no entregas. El riesgo en cualquier sensibilidad declarada es el producto punto de la Ec. (3). El tamaño esperado sigue siendo descriptivo; la utilidad heredada basada en tamaño se vincula de forma diagnóstica con el macro-recobrado, pero no ordena los brazos.

5. Protocolo de evaluación

El protocolo estima primero el vector completo de frecuencias de cada brazo y después deriva la dominancia y la geometría de cambio para toda pérdida normalizada. No necesita un punto de pérdida, y ningún contraste empírico se ejecutó para escribir esta sección.

5.1. Orden de particiones y formación de pares

Los bancos empíricos son la modalidad óptica de PASTIS-R [18] y Breizh-Crops [17]. Nombrar PASTIS-R identifica el banco distribuido; ningún canal radar entra a los predictores evaluados.

La cohorte de referencia elegible del fold cinco de PASTIS-R contiene 16640 parcelas. Sus cuatro clases más frecuentes reúnen el 72.0 % de las parcelas y las seis más raras el 6.5 %. Son proporciones de parcelas, no de superficie; el mosaico de la Fig. 3 es deliberadamente esquemático y no geográfico.

Entrenamiento fija el universo neutral y el catálogo por soporte; validación fija los demás componentes del punto de operación; evaluación empieza solo cuando ambos son inmutables. Las identidades estables imponen particiones disjuntas e impiden aplicar un punto ajustado a cualquier identidad de entrenamiento o validación, incluso una fila copiada; la igualdad de posteriores es irrelevante.

El tamaño común del catálogo es el prefijo más corto de clases ordenadas por soporte de entrenamiento cuya masa acumulada alcanza 0,9, desempataando por id de clase; las reglas por F y soporte usan ese mismo tamaño. Validación fija una entrega objetivo de 0,9 para abstención, un desajuste de 0,1 para el conjunto adaptativo y una tasa precisa de hoja de 0,9 para retroceso. Una clase entra al universo neutral con al menos 20 parcelas de entrenamiento. Son puntos de intervención nominales elegidos por los autores, no puntos de igual pérdida, y no se reigualan en la partición retenida.

El evaluador asigna cada parcela retenida y cada brazo a uno de los siete resultados cerrados. El pareo usa identidad, bloque y `patch_id`; reordenar filas es válido, pero omitir, duplicar o sustituir no. El universo derivado de entrenamiento viaja con el perfil y nunca se reconstruye desde evaluación o desde una réplica bootstrap.

Ambos bancos habían sido inspeccionados antes de esta ejecución y siguen siendo exploratorios. Un registro cerrado no admitió un banco confirmatorio

Casi todo el mosaico son cuatro cultivos
una celda = una parcela; posición esquemática




Figura 3. Soporte exacto por clase en la cohorte de referencia elegible del fold cinco de PASTIS-R. Cada microcelda representa una parcela; solo el conteo es literal. Posición y forma no codifican geografía ni superficie. Las cuatro clases principales aparecen por separado, seguidas por las ocho intermedias y las seis más raras.

separado; es un resultado acotado a los candidatos registrados, no una afirmación exhaustiva sobre los datos públicos.

5.2. Dos vistas declaradas de incertidumbre

Para cada par de brazos y celda, el contraste es el indicador del brazo izquierdo menos el de su comparador. La vista primaria remuestrea grupos completos de `patch_id` dentro de bloques, lleva juntas todas las parcelas y brazos y combina bloques con sus pesos parcelarios originales. No hay bootstrap de parcelas.

Por separado, las diferencias se promedian dentro de bloques espaciales y esas medias reciben peso igual. Un intervalo de Student pareado sobre una coordenada o sección declarada expone la variación entre bloques sin tratar folds superpuestos como regiones independientes. Su centro puede diferir del contraste poblacional cuando cambian los tamaños; forzar igualdad cambiaría el estimando.

Ambas vistas conservan el denominador completo. Por debajo de tres unidades pareadas únicas, se devuelven deltas y una razón, pero no intervalo, valor p ni elegibilidad Holm. Una comparación declarada idéntica por construcción se conserva como autocontrol y se excluye de multiplicidad.

Cuadro 1. Políticas de salida fijas en la comparación primaria de seis brazos. La tabla describe instancias, no toda la familia de puntos de operación posibles.

Política	Fijado antes de evaluación	Respuesta visible
Singleton base	Máximo de la posterior	Una etiqueta hoja
Catálogo por soporte	Prefijo mínimo que alcanza masa 0,9 en entrenamiento	Etiqueta o silencio
Catálogo por F-score	Mismo tamaño, orden con-gelado alternativo	Etiqueta o silencio
Abstención	Umbral de validación para entrega 0,9	Etiqueta o silencio
Conjunto adaptativo	Masa split-conformal $\alpha = 0,1$	Conjunto no vacío
Retroceso HCAT4	Umbral de validación para 0,9 de hojas precisas	Hoja o clase gruesa

5.3. Dominancia, fronteras y multiplicidad

Cada estrato contiene todos los pares no ordenados y las seis coordenadas con coste. Para un par ordenado, el escalar primario es

$$D_{m,n} = \max_{j=1,\dots,6} (q_{m,j} - q_{n,j}). \quad (4)$$

La dominancia componente a componente observada es descriptiva. Una afirmación inferencial exige que toda cota unilateral simultánea sea a lo sumo cero y al menos una estrictamente menor. Las cotas vienen de un estadístico máximo sobre la familia completa. No se retiran pares ni coordenadas después de verlos. Si falta una comparación o tiene pocos clústeres, se retiene la afirmación simultánea afectada y quedan disponibles los vectores descriptivos.

El procedimiento primario congelado usa alfa familiar 0,05, intervalos del 95 %, 9,999 remuestreos pareados de parches dentro de bloque, probabilidades bootstrap add-one y semilla 20260909. En cada estrato confirmatorio, el valor crítico es el máximo absoluto de la desviación estudentizada centrada sobre los 15 pares y 6 costes: 90 coordenadas o 180 desigualdades direccionales. Un error estándar cero retiene la afirmación, salvo donde ninguna acción pueda producir ese resultado: la diferencia es cero exacto en todo clúster, por lo que la cota exacta es cero y no lleva probabilidad bootstrap. Esta cota estructural es esencial; sin ella el par no puede conservar seis coordenadas acotadas. Registramos la aclaración después de ejecutar y rederivamos las dos salidas afectadas antes del envío. La estudentización se recalcula dentro de cada réplica con su propio error de parche centrado por bloque; se prohíbe reutilizar un denominador. Una relación entre predictores usa intersección–unión y debe sostener la misma dirección en todo estrato predeclarado; no se elige el predictor favorable.

La región ganadora ajustada de m es la intersección del simplex con los semiespacios $(\mathbf{q}_m - \mathbf{q}_n)^T \boldsymbol{\ell} \leq 0$ para cada comparador n . La frontera de un par es la igualdad. Estos objetos usan todas las coordenadas y no requieren una medida

de probabilidad sobre el s mplex. Toda secci n bidimensional debe declarar qu  fija; no puede rotularse como mapa completo ni convertirse en umbral escalar universal.

Las p rdidas puntuales se limitan a sensibilidades no confirmatorias con fuente externa o secci n geom trica declarada. No seleccionan el punto de operaci n, no definen la familia primaria ni sustentan una preferencia de parte interesada. Razones y conjuntos de Fieller anteriores quedan fuera del an lisis primario.

6. Resultados

Reportamos contabilidad exploratoria de resultados, no una preferencia universal. La Fig. 4 muestra el objeto emp rico detr s de toda comparaci n antes de aplicar una p rdida. El intercambio queda visible: la abstenci n mueve masa de errores precisos al silencio; los conjuntos adaptativos mueven la mayor parte hacia respuestas ambiguas que contienen la verdad; el retroceso introduce entregas gruesas correctas e incorrectas. Ning n movimiento tiene signo hasta asignar coste a sus celdas.

Para los 5 predictores congelados de PASTIS-R, el atlas primario no certific  dominancia: 71 de 75 pares de acciones fueron ciertamente incomparables y 4 quedaron indeterminados, no empatados. La ausencia de dominancia se mantuvo en las diez semillas. El hallazgo hist rico de que ninguna partici n espacial fue seleccionada fall  en todas las semillas y se retira; sin perfiles de selecci n por semilla no reportamos reemplazo.

No existe un punto de p rdida prerregistrado que marcar: seleccionar uno est  prohibido. En las secciones planas declaradas, la l nea base singleton, los conjuntos adaptativos, la abstenci n y el retroceso taxon mico ganaron en alg n lugar; ninguna pol tica de cat logo gan  un punto muestreado. Esto establece cambios en la rejilla declarada, no una probabilidad de ser mejor ni un volumen del s mplex.

La Fig. 5 muestra la primera secci n de la enumeraci n exhaustiva, con $L_4 = L_5 = L_6 = 0,1$ y sin agrupar predictores. Se eligi  para mostrarla despu s de materializar, no fue prerregistrada. Las 20 secciones bidimensionales declaradas contienen 66 puntos de rejilla cada una y siguen disponibles en el artefacto estructurado.

BreizhCrops no aporta un atlas inferencial pareado. Cada estrato modelo-regi n contiene 1 cl ster bajo la unidad congelada, por debajo del m nimo de 3; no son estimables intervalos simult neos, dominancia ni fronteras de fase. Sus perfiles siguen descriptivos y no se agrupa con PASTIS-R para fabricar replicaci n.

La masa conforme y el umbral preciso HCAT4 se ajustaron en validaci n. Ambas entregas quedaron fijadas antes de abrir las etiquetas de evaluaci n; la disponibilidad de referencias solo restringi  entregas ya fijadas de PASTIS-R. Sus objetivos de validaci n son restricciones distintas, no una p rdida igual.

Cada fila conforme cumpli  su objetivo marginal, pero devolviendo respuestas m ltiples. HCAT4 recuper  entregas adicionales que conten an la verdad en cada

DeepLabv3+							
singleton	64.9	35.1	0.0	0.0	0.0	0.0	0.0
catálogo soporte	63.4	31.7	4.8	0.0	0.0	0.0	0.0
catálogo F1	63.5	30.7	5.8	0.0	0.0	0.0	0.0
abstención	62.2	26.7	11.1	0.0	0.0	0.0	0.0
conjunto	5.8	0.3	0.0	91.1	2.8	0.0	0.0
retroceso	62.9	28.5	0.0	0.0	0.0	4.3	4.3
SegFormer							
singleton	64.7	35.3	0.0	0.0	0.0	0.0	0.0
catálogo soporte	63.5	33.0	3.5	0.0	0.0	0.0	0.0
catálogo F1	63.2	32.0	4.7	0.0	0.0	0.0	0.0
abstención	61.7	27.0	11.3	0.0	0.0	0.0	0.0
conjunto	5.5	0.1	0.0	92.2	2.2	0.0	0.0
retroceso	62.3	28.5	0.0	0.0	0.0	5.3	3.9
TSViT-Pheno							
singleton	85.8	14.2	0.0	0.0	0.0	0.0	0.0
catálogo soporte	79.9	12.4	7.7	0.0	0.0	0.0	0.0
catálogo F1	77.4	10.5	12.1	0.0	0.0	0.0	0.0
abstención	80.6	7.6	11.8	0.0	0.0	0.0	0.0
conjunto	6.8	0.1	0.0	91.6	1.5	0.0	0.0
retroceso	82.3	9.5	0.0	0.0	0.0	5.0	3.2
TSViT-FullIM							
singleton	88.1	11.9	0.0	0.0	0.0	0.0	0.0
catálogo soporte	81.4	10.2	8.4	0.0	0.0	0.0	0.0
catálogo F1	77.1	7.8	15.1	0.0	0.0	0.0	0.0
abstención	81.9	5.5	12.6	0.0	0.0	0.0	0.0
conjunto	6.7	0.1	0.0	91.9	1.3	0.0	0.0
retroceso	84.1	7.3	0.0	0.0	0.0	5.4	3.2
U-Net							
singleton	55.4	44.6	0.0	0.0	0.0	0.0	0.0
catálogo soporte	55.1	43.8	1.1	0.0	0.0	0.0	0.0
catálogo F1	55.3	43.9	0.8	0.0	0.0	0.0	0.0
abstención	52.5	35.3	12.2	0.0	0.0	0.0	0.0
conjunto	2.7	0.3	0.0	90.9	6.1	0.0	0.0
retroceso	53.8	38.5	0.0	0.0	0.0	3.4	4.3
	R0	L1	L2	L3	L4	L5	L6
	correcta						

Figura 4. Perfiles completos de frecuencia en PASTIS-R para cada predictor congelado y política primaria. Las celdas son porcentajes de la misma cohorte con referencia válida. El tono repite la magnitud impresa y no es el único canal. Las columnas contienen la referencia de pérdida cero y las seis celdas con coste de la Sección 3.2.




Figura 5. Regiones de ganador cierto en una sección declarada del atlas exploratorio PASTIS-R. Los símbolos identifican la acción ganadora; las cruces son evaluaciones donde la banda simultánea no establece una. Cada panel es un predictor congelado. Las acciones de restricción del catálogo permanecen en la leyenda aunque ninguna gane en esta sección, cerrando la cuenta de seis acciones. La sección mostrada es la primera de la enumeración congelada y fue elegida para presentación después de obtener resultados.

fila, pero también emitió respuestas gruesas incorrectas en cada una. Su tasa precisa realizada varió entre estratos pese a un objetivo único de validación. Una clase gruesa nombrada no es rescate gratuito ni el mismo objeto que un conjunto arbitrario que contiene la verdad.

La calibración conforme marginal no implicó cobertura condicional por clase: una clase U-Net de PASTIS-R contuvo la verdad en 28 de 206 conjuntos. El soporte extremo histórico en BreizhCrops fue 6 parcelas; los extremos por semillas abarcaron 1–6 y no sostienen generalización por clase.

Las filas usan cohortes de evaluación con referencia válida: 16640 parcelas PASTIS-R y 30000 parcelas BreizhCrops por región externa. Las otras 11892 identidades posteriores de PASTIS-R no tienen una referencia semántica válida para esta cuenta. La entrega se fijó antes de aplicar ese filtro, por lo que este no puede mejorar su tasa; esas identidades tampoco se describen en silencio como parcelas evaluadas.

Juntos, perfiles y atlas responden la pregunta más estrecha que permiten los datos: qué política se prefiere para una pérdida declarada sobre seis celdas y dónde cambia esa preferencia. No identifican la pérdida misma.

7. Discusión

Los diagnósticos muestran por qué una sola tasa de éxito no responde a la pregunta de decisión. Los conjuntos conformes logran contención marginal al devolver varias etiquetas; HCAT4 a veces recupera la verdad mediante un padre comunicable y a veces devuelve el padre equivocado. Declarar que cualquiera es uniformemente mejor pondría de forma implícita precio cero a la amplitud o al error grueso, por lo que las coordenadas de resultado deben permanecer separadas.

La afirmación de cobertura está condicionada a cada banco evaluado y a la intercambiabilidad entre sus parcelas de calibración y evaluación. Ambos bancos ya habían sido inspeccionados antes de esta ejecución, de modo que todos los resultados son exploratorios aunque las particiones de evaluación se mantengan fuera de la calibración. No se deriva ninguna afirmación de transporte, y la búsqueda cerrada no halló otro banco confirmatorio admisible. La variación entre predictores es sensibilidad, no una vía para seleccionar un modelo favorable. PASTIS-R sostiene por ello un atlas de decisión exploratorio; BreizhCrops sostiene perfiles descriptivos, pero no inferencia pareada, porque su estructura de reporte congelada tiene solo 1 clúster por estrato modelo-región.

La ausencia de dominancia certificada no es un empate: los perfiles que se cruzan y las victorias de cuatro acciones rechazan un orden independiente del precio y localizan sus cambios. Que la restricción del catálogo no gane ningún punto muestreado no prueba que sus regiones tengan volumen cero, pues la rejilla no define una medida sobre el simplex. La conclusión sobre agrupamiento espacial cambió bajo la rejilla congelada de semillas; la retiramos en vez de elegir una partición favorable después de observar el atlas.

Dos restricciones de alcance son esenciales. Primero, cada brazo es una política de operación fija; el estudio no ordena cada miembro posible de su familia. Segundo, la cuenta de seis celdas olvida a propósito cardinalidad del conjunto, profundidad taxonómica y qué par de cultivos fue confundido. Un uso que cobre cualquiera de esas distinciones necesita ampliar la base antes de aplicar la misma geometría.

Los checkpoints heredados de PASTIS-R no registran semillas de entrenamiento en sus fuentes de identidad. La sensibilidad a semillas solo puede reejecutar etapas estocásticas posteriores al entrenamiento para esos miembros; no establece robustez frente a la aleatoriedad de entrenamiento. No rellenamos esa afirmación reentrenando después de observar el atlas. Se conservan los predichos estables; los conteos que cambiaron se reportan como rangos. El muestreo y los ajustes clásicos de BreizhCrops siguen siendo reejecutables y separados, sin agregarlos.

La robustez al ruido de etiqueta tampoco está medida: no se declaró un modelo de transición entre clases específico de cada banco y la familia secundaria retenida no aporta un objetivo estimable de corrupción. Por ello no inyectamos un proceso sintético conveniente después de ver los resultados.

Disponibilidad de datos y código

El archivo anónimo contiene el proyecto L^AT_EX, la bibliografía, el apéndice generado y las figuras, pero no datos satelitales crudos. Los artefactos exploratorios, contratos y código de regeneración permanecen privados durante la revisión y acompañarán un archivo citable antes de la publicación. Los datos fuente conservan las condiciones de sus proveedores; quienes repliquen el trabajo reejecutarán el atlas y las figuras desde los conteos de resultados depositados, no desde las imágenes.

Referencias

1. Barriere, V., Claverie, M., Schneider, M., Lemoine, G., d’Andrimont, R.: Boosting crop classification by hierarchically fusing satellite, rotational, and contextual data. *Remote Sensing of Environment* **305**, 114110 (2024). <https://doi.org/10.1016/j.rse.2024.114110>
2. Carvalho, T., Martinez, J.A.C., Oliveira, H., dos Santos, J.A., Feitosa, R.Q.: Outlier exposure for open set crop recognition from multitemporal image sequences. *IEEE Geoscience and Remote Sensing Letters* **20**, 1–5 (2023). <https://doi.org/10.1109/LGRS.2023.3244532>
3. Chow, C.: On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory* (1970). <https://doi.org/10.1109/tit.1970.1054406>
4. Chzhen, E., Denis, C., Hebiri, M., Lorieul, T.: Set-valued classification — overview via a unified framework (2021)
5. Geifman, Y., El-Yaniv, R.: Selective classification for deep neural networks. In: *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. pp. 4878–4887. Curran Associates (2017), <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>
6. Geifman, Y., El-Yaniv, R.: SelectiveNet: A deep neural network with an integrated reject option. In: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. *Proceedings of Machine Learning Research*, vol. 97, pp. 2151–2159. PMLR (2019), <https://proceedings.mlr.press/v97/geifman19a.html>
7. Ghassemi, B., Izquierdo-Verdiguier, E., d’Andrimont, R., Vuolo, F.: How accurately and in what detail can land use and land cover be mapped using copernicus Sentinel and LUCAS 2022 data? *Remote Sensing* **17**(8), 1379 (2025). <https://doi.org/10.3390/rs17081379>
8. Gimenez, R., Laloue, A., Fabre, S.: Rejection methods for vegetation mapping using hyperspectral airborne data. *International Journal of Remote Sensing* **44**(16), 4937–4962 (2023). <https://doi.org/10.1080/01431161.2023.2240520>
9. Gonzalez-Calabuig, M., Cohrs, K.H., Nedungadi, V., Osika, Z., Cartuyvels, R., Knoblauch, S., Massant, J., Nath, S., Ebel, P., Sitokonstantinou, V.: SHRUG-FM: Reliability-aware foundation models for Earth observation. In: *Proceedings of the*

- IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. pp. 7919–7928 (2026)
10. Ha, T.M.: The optimum class-selective rejection rule. *IEEE Transactions on Pattern Analysis and Machine Intelligence* **19**(6), 608–615 (1997). <https://doi.org/10.1109/34.601248>
11. Jones, E., Sagawa, S., Koh, P.W., Kumar, A., Liang, P.: Selective classification can magnify disparities across groups. In: 9th International Conference on Learning Representations (ICLR) (2021), https://openreview.net/forum?id=NOM_4BkQ05i
12. Liu Ziyin, Wang, Z., Liang, P.P., Salakhutdinov, R., Morency, L.P., Ueda, M.: Deep gamblers: Learning to abstain with portfolio theory. In: *Advances in Neural Information Processing Systems 32* (NeurIPS 2019). pp. 10622–10632. Curran Associates (2019), <https://proceedings.neurips.cc/paper/2019/hash/0c4b1eeb45c90b52bfb9d07943d855ab-Abstract.html>
13. Mortier, T., Hüllermeier, E., Dembczyński, K., Waegeman, W.: Set-valued prediction in hierarchical classification with constrained representation complexity. In: *Proceedings of the Thirty-Eighth Conference on Uncertainty in Artificial Intelligence*. *Proceedings of Machine Learning Research*, vol. 180, pp. 1392–1401. PMLR (2022), <https://proceedings.mlr.press/v180/mortier22a.html>
14. Mortier, T., Wydmuch, M., Dembczyński, K., Hüllermeier, E., Waegeman, W.: Efficient set-valued prediction in multi-class classification. *Data Mining and Knowledge Discovery* **35**, 1435–1469 (2021). <https://doi.org/10.1007/s10618-021-00751-x>
15. Pugnana, A., Ruggieri, S.: AUC-based selective classification. In: *Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS)*. *Proceedings of Machine Learning Research*, vol. 206, pp. 2494–2514. PMLR (2023), <https://proceedings.mlr.press/v206/pugnana23a.html>
16. Rey, M., Mnih, A., Neumann, M., Overlan, M., Purves, D.: Uncertainty evaluation of segmentation models for Earth observation (2025)
17. Rußwurm, M., Pelletier, C., Zollner, M., Lefèvre, S., Körner, M.: BreizhCrops: A time series dataset for crop type mapping. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences* **XLIII-B2-2020**, 1545–1551 (2020). <https://doi.org/10.5194/isprs-archives-XLIII-B2-2020-1545-2020>
18. Sainte Fare Garnot, V., Landrieu, L., Chehata, N.: Multi-modal temporal attention models for crop mapping from satellite time series. *ISPRS Journal of Photogrammetry and Remote Sensing* **187**, 294–305 (2022). <https://doi.org/10.1016/j.isprsjprs.2022.03.012>
19. Turkoglu, M.O., D’Aronco, S., Perich, G., Liebisch, F., Streit, C., Schindler, K., Wegner, J.D.: Crop mapping from image time series: Deep learning with multi-scale label hierarchies. *Remote Sensing of Environment* **264**, 112603 (2021). <https://doi.org/10.1016/j.rse.2021.112603>